

风控方向面试题

目录

风控	1
1. 互联网金融场景下的的风控模型种类?	5
2. 简单描述一下风控建模的流程?	5
4. 对于金融场景, 稳定胜于一切, 那在建模过程中如何保证模型的稳定性?	6
5. 为什么要做拒绝推断? 常用的拒绝推断方法有哪些?	6
6. 模型转化为规则后决策点 (cutoff 点) 怎么设定?	7
7. 怎么做风控模型的冷启动?	7
8. 模型上线后是怎么监控的?	8
9. 怎么设计反欺诈模型?	9
10. 当模型上线后发现稳定性不佳, 或者线上的区分效果不好, 你是怎么对模型作调整的?	9
11. 如何衡量一个风控模型的效果?	10
12. 在实际应用中, 如何权衡模型的性能, 可解释性和部署的难易程度?	10
13. 对于高维稀疏特征, 或者是弱特征, 你是怎么处理的?	11
14. 对于成千上万维的特征你是怎么做特征筛选的, 如何保证其模型的可解释性和稳定性?	11
15. 如何根据风险因素对用户分层, 构建客群差异化的模型?	12
16. 额度, 利率的风险定价模型你是如何设计的?	12
17. 风控流程中不同环节的评分卡是怎么设计的?	12
18. 芝麻信用分的主要计算维度?	13
19. 如果用 borderline_smote 会不会导致某一箱内坏的比例过大呀?	13
20. 有什么好的模型调参的方法么? 网格搜索? 贝叶斯优化?	13
21. U 型特征怎么转化为单调?	13
22. 什么是 baviar 图?	14
23. 采样怎么做效果才会好?	14
24. 什么我们做评分卡的时候要用 woe 编码, 而不是用别的编码方式呢? 比如 onehot 之类的, 仅仅是因为 woe 可以把特征从非线性变成线性的吗?	14
25. 深度学习的风控模型, 从经验上看, 样本量大概要多少条啊	14
26. 分箱后, 各箱 badrate 单调递增从业务上怎么理解呀?	14
27. 我这更换了数据源 现在有标签的样本只有一万过条 有什么方法建议的吗?	14
28. 5 万正样本, 200 负样本, B 卡, 不只是提高额度, 会拒绝一部分客户, 怎么建模?	14
29. leader 给我的任务是对短信打标签, 也就是判断出短信属于的标签是哪一类, 这样一个任务是提取文本关键词的任务吧?	15
30. 简单的除了之前说的那种统计坏的词, 然后正则匹配的还有其他的吗? leader 之前说拿到词的重要度, 是在整个语料中的一个重要度的话, tf-idf 是不可行的, 现在要出一个版本的话, 您有什么建议吗?	15
31. 请问欺诈标签如何定义?	15
32. 最近面试数据分析师岗位, 和算法岗有什么不一样么? 会提到数据敏感, 究竟	

应该怎么回答？	15
33. 现在公司是不是先准入规则，然后再进入一个 pre-A 模型，然后再是反欺诈模型，然后是 A 卡之类的？	16
34. 准入规则，pre-A，反欺诈规则反欺诈引擎，还有风控模型，一般都不会选用相同的特征？因为客户群体会越来越少	16
35. 用三种标签学出来的三个模型，从三个维度给一个人的欺诈风险打分，怎么给这三个模型进行融合，因为单个用户申请线上预测，无法根据客户在各个模型排名取平均。但这三个模型的输出的概率区间又是不同的，比如模型 A 的输出区间是[0-0.4]，模型 B 输出区间[0-0.9]，也不是正态分布，zscore 标准化不能用，只能 MinMax 先进行标准化？再进行分数融合？	16
36. 在风控场景下，有时候我们会对用户行为序列建模，那在使用 BiLSTM 对用户行为进行建模时，神经网络的输入层是什么？输出层是什么？怎么把用户行为数据转换成神经网络输入层的向量？	16
37. 在 xgboost 或者 lightgbm 建模之前是否进行相关性处理，去掉相关性较高的变量？	17
38. 在评分卡上线以后。进行监控的时候，监控的周期是多少，是将新数据下载到本地来计算 ks、psi 以及变量稳定性等这些指标吗？	17
39. 不平衡场景下的过采样（朴素、SMOTE）后训练的模型都需要结果概率校正吧？如何操作？	17
40. 请问回归决策树针对离散变量使用，是否先转成 one-hot？否则 1）如果是没转码的字符变量。直接报错 2）如果转成数值。就会把我们的编码，当做连续变量进行回归处理？	17
41. 比如说在建模的时候，有一个特征是性别，我是应该在男和女情况下建立两个模型 还是 将性别放进 x 里建立一个模型	18
42. 对于分期账单，在进行逾期分析的时候，是以每个到期用户的第一期来计算，还是以每个到期用户的最近那个到期来计算，还是按照账单每一期来计算？现在就是出现有些用户，第一期没有逾期，但第二期就会逾期或者不还这种就是把每一期当做账单或者一个人，然后进行分析？	18
43. KS 值=max (TPR—FPR) 的说法对吗？怎么图形和公式都和上课老师讲的很像，这个公式可以在 KS 曲线上求出来，通过改变概率阈值。KS 值和 KS 曲线通过调节概率阈值，得出的 KS 值是一回事吗？	18
44. 计算模型的 psi 一般用等频分还是等距分？一般分几份？	18
45. lgb 在不平衡分类上训练了一个模型，训练集上输出概率分布呈偏态分布（偏向 0，好样本），但在测试集上呈近似正态分布。如果设置 pos_scale_weight 参数，会产生这种情况，如果不设置，测试集上的概率分布还是和训练集类似这种现象正常吗？	18
46. 如何标记客户好坏的？	19
39. 做模型时用到了哪些数据源？	19
46. 你们模型是怎么部署上线的？	19
47. xgb 变量重要性用哪一个指标？	19
48. 如果我们做完模型，只是一个人逾期的概率，那不同的人还有不同的额度和手续费，我们直接对最终收益进行建模那多好？？最大化收益不就是我们的业务目标么？	20
49. 什么是多头借贷？	20

50. 模型开发中, one-hot 编码好还是哑变量编码好?	20
51. 市面上很多数据机构, 特征变量时间用累计的, 30 天, 90 天, 180 天这样累计的, 尤其是一些多头申请数据。那这样是不是意味着特征衍生是不够专业或者还存在缺失的。	20
52. 模型的 ks 和 auc 有多少可以上线了? 一般训练集和测试集之间的 ks 和 auc 相差多少算是比较合理的呢?	21
53. A 和 B 相关性强, B 和 C 相关性强, 这种情况去除哪个变量?	21
54. 关于缺失值处理。您提到, 某些变量不应该处理, 标记出来即可, 我理解这是针对分类变量。假设类似芝麻分, 缺失了 60%, 但剩下的 40%依然能看出 KS, 这时候除了做是否确实芝麻分的衍生外, 也想保留芝麻分的数值型特征, 但此时使用中位数, 或者平均数, 填充, 其实都会严重影响 芝麻分的分布。不知道, 您是怎么处理的? 21	
55. 现在做 xgb 模型还需要分箱编码嘛?	21
56. lr 那种模型里变量分箱编码以后都是单调齐次的了, 树模型并不需要这种性质是不是及时树模型做了分箱也没必要分的很少几个 bin 弄成单调的, 只是分几个箱防止过拟合就可以了?	21
57. 分箱法的主要目的?	22
58. 请问类似特征 “近 30 天通过率”, 出现空值的情况应该怎么处理? 因为这是因为用户近 30 天没有申请。补 0 的话, 会和用户有申请但没有通过件这样的情况混淆。补其他值感觉也不符合业务逻辑。	22
59. 要是公司里做 lgb 的 A 卡, 我搓出来几千维特征模型重要度都>0, 这种模型能用吗?	22
60. 请问无监督做特征选择都有什么方法呀?	22
61. 做特征衍生的时候 经常会衍生出不稳定的特征(训练与测试集上分布相差比较大) 有没有什么自动化的方法可以帮助剔除和检验出这些特征呢?	22
62. 下探一般要选多少样本进行下探? 下探的样本评分很低, 但选取哪些呢? .	22
63. 训练出来的模型如果出现了误判的情况(假正和假负), 应该怎样去让模型学到这部分误判的情况, 而后正确的预测呢? 一般是怎么操作的呢?	22
64. 实际分箱过程中如果用等频分箱, 怎么使得每箱都有好坏样本, 保证后面计算 WOE 有意义?	23
65. 地址数据具体怎么用比较好?	23
66. 计算模型的 psi 一般用等频分还是等距分? 一般分几份?	23
67. 不平衡场景下的过采样(朴素、SMOTE)后训练的模型都需要结果概率校正吧?	23
68. feature_importance 和 iv 有时候选出的变量差别很大, 该以哪个为准, 怎么判别	23
69. 怎么解决测试集上 auc 偏低的问题? 我这个数据集比较小, 训练集有 1000 个, 是前 20 天, 测试集有 200 多个, 是后 10 天, 这个是纯多头数据, 原始多头变量 120 个, 自己做衍生变量到 7000 左右。训练集违约率 20%左右, 测试集违约率 14%左右。24	
70. 如果客群风险发生变化, 会怎么做? 是不是	24
1) 看变化前后用户特征(重要特征)的分布是否发生变化	24
2) 是不是有欺诈的可能	24
3) 如果以上都不是, 是不是需要调整准入规则或者申请模型。	24
71. 一般在业务中哪种分箱用得更多啊?	24
72. 现在市面上在金融风控中用的无监督算法都有哪些?	24

73. 利用 rf 看特征的重要性, 碰到了类别型的特征, 是直接做 one_hot 处理还是分箱转为 woe, 或者不参与特征的排序	24
74. 构建一个申请评分卡需要多长时间, 就是从数据库选择数据、拉取数据, 到最后生成一个评分卡需要多久, 然后部署上线稳定运行又需要多长时间?	24
75. 有 30 天的放款表现数据, 其中有不连续 10 天的用户逾期率较低, 有不连续 20 天的用户逾期率较高, 那么一般是什么原因造成, 该怎么找到造成这样的原因? ..	25
76. 进行线性相关性和多重共线性检验的时候, 特征是用原始特征还是 WOE 编码后的特征呢?	25
77. 对于评分卡模型, 是先特征选择还是先对特征进行分箱处理? 对于特征非常多的情况下, 分箱的效果也不太好, 我就考虑是不是先对特征进行选择再处理呢? ..	25
78. 对于信贷评分卡模型 数据量一般在多少范围比较合适?	25
79. 小微正常过反欺诈, 主要考虑哪些?	26
80. 我们的模型基本上都是基于样本不均衡的数据的, 那么问题就来了, 特征工程里不做采样处理的话, 样本是极不均衡的, 那么做出来的模型有的时候也会失真。如果做采样的话, 那么虽然模型有保证了, 但是训练模型的好坏分布并不符合线上的实际好坏分布。这个问题怎么解决呢?	26
81. 如果采样特征完备性比较好, 是不是采样全中就不需要考虑了。或者这个权重怎么把它和 ks 计算结合起来?	26
82. ks 指标计算, 会考虑这个权重吗, 还是继续使用采样过后的?	26
83. neo4j 上线, 实时构建图谱的性能如何?	26
84. 无监督与 xgboost 结合的反欺诈模型该如何做?	26
85. 根据业务构造损失函数, 能举个例子么?	27
86. 催收主要工作就是失联修复, 本质上是催收成本与收益的平衡, 过程中需要考虑安全与体验性, 这样说对吗?	27
87. 催收策略是如何设计、优化, 具体怎么制定及优化催收策略。策略规则在决策引擎中是怎么测试及部署上线的?	28
88. 评分卡做好以后, 先在原有基础上等上一段时间, 积累一定的数据量, 然后再将积累的数据和线下的评分模型比较; 那么我上线以后, 在通过一些指标监控的时候, 什么样的情况下模型变得不好需要重新调整, 什么样的情况下模型良好而不需要调整?	29
89. 怎么更新评分卡或模型, 比如通过决策规则获得数据构建评分卡或模型, 上线一段时间之后, 想更新模型, 该用什么数据去建模	29

风控

1.互联网金融场景下的的风控模型种类？

获客阶段：用户响应模型，风险预筛选模型。

授信阶段：申请评分模型，反欺诈模型，风险定价模型，收益评分模型。

贷后阶段：行为评分模型，交易欺诈模型，客户流失模型。

催收阶段：早期催收模型，晚期催收模型。

2.简单描述一下风控建模的流程？

前期准备工作：不同的模型针对不同的业务场景，在建模项目开始前需要对业务的逻辑和需求有清晰的理解，明确好模型的作用，项目周期时间和安排进度，以及模型效果的要求。

模型设计：包括模型的选择（评分卡还是集成模型），单个模型还是做模型的细分，是否需要做拒绝推论，观察期，表现期的定义，好坏用户的定义，数据的获取途径等都要确定好。

数据拉取及清洗：根据观察期和表现期的定义从数据池中取数，并进行前期的数据清洗和稳定性验证工作，数据清洗包括用户唯一性检查，缺失值检查，异常值检查等。稳定性验证主要考察变量在时间序列上的稳定性，衡量的指标有 PSI，平均值/方差，IV 等。

特征工程：主要做特征的预处理和筛选，如果是评分卡，需要对特征进行离散化，归一化等处理，再对特征进行降维，降维的方法有 IV 筛选，相关性筛选，显著性筛选等。另外会基于对业务的深入理解做特征构造工作，包括特征交叉，特征转换，对特征进行四则运算等。

模型建立和评估：选择合适的模型，像评分卡用逻辑回归，只需要做出二分类预测可以选择 xgboost 等集成模型，模型建好后需要做模型评估，计算 AUC,KS，并对模型做交叉验证来评估泛化能力及模型的稳定性。

模型上线部署：在风控后台上配置模型规则，对于一些复杂的模型还得需要将模型文件进行转换，并封装成一个类，用 Java 等其他形式来调用。

模型监控：前期主要监控模型整体及变量的稳定性，衡量标准主要是 PSI，并每日观察模型规则的拒绝率与线下的差异。后期积累一定线上用户后可评估线上模型的 AUC,KS，与线下进行比较，衡量模型的线上的实际效果。

3.评分卡，集成模型在线上是如何部署的？

评分卡的部署较为简单，因为评分卡将变量映射到了一个个区间及得分，所以在普通的风控决策引擎上就可配置。

像一些比较复杂的模型，例如 xgboost 和 lightgbm，一般是将模型文件转换为 pmml 格式，并封装 pmml，在风控后台上上传 pmml 文件和变量参数文件，并配置好模型的阈值。python 模型和 R 模型都可以用这种方式来部署。

4.对于金融场景，稳定胜于一切，那在建模过程中如何保证模型的稳定性？

在数据预处理阶段可以验证变量在时间序列上的稳定性，通过这个方法筛掉稳定性不好的变量，也能达到降维的目的。筛选的手段主要有：计算月 IV 的差异，观察变量覆盖率的变化，两个时间点的 PSI 差异等。

异常值的检查，剔除噪声，尤其对于逻辑回归这种对于噪声比较敏感的模型。

在变量筛选阶段剔除与业务理解相悖的变量，如果是评分卡，可以剔除区分度过强的变量，这种变量一般不适合放入模型中，否则会造成整个模型被这个变量所左右，造成模型的稳定性下降，过拟合的风险也会增加。

做交叉验证，一种是时间序列上的交叉验证，考察模型在时间上的稳定性，另一种是 K 折随机交叉验证，考察模型的随机稳定性。

选择稳定性较好的模型，例如随机森林或 xgboost 这类泛化能力较好的模型。

5.为什么要做拒绝推断？常用的拒绝推断方法有哪些？

①拒绝推断的目的：

如果只用好坏用户建模，则忽略了那些授信被拒的用户，加入拒绝用户是为了让建模样本更接近总体的分布，防止样本有偏，同时也能增加样本数量。

公司内部策略的变动，导致当前的申请者已不能代表建模时点的申请者，所以过去被拒的用户不一定现在也会被拒绝，因此，只使用审批通过的用户可能会造成误判。

做拒绝推断可以找出之前被拒的好用户，挖掘这些用户，改善风控流程，增加公司收益。

②拒绝推断的适用范围：

高核准率不适合用拒绝推断，因为高核准率下好坏用户已接近于整体的申请用户。中低核准率适用拒绝推断。

③拒绝推断的常用方法：

硬性截断法：先用好坏用户建立初始模型，然后用这个初始模型对拒绝用户进行打分，设定一个阈值分数（根据对拒绝用户的风险容忍度），低于这个阈值的为坏用户，高于这个阈值的为好用户。再将已标记好的拒绝用户放入样本中，重新建立模型。

分配法：此方法适用于评分卡，先用好坏用户建立初始评分卡模型，再将样本根据评分高低进行分组，计算各分组的违约率。然后对拒绝用户进行打分并按此前的步骤进行分组，以各分组的违约率为抽样比例，随机抽取改分组下的违约用户，指定其为坏用户，剩下的则是好用户。最后将已标记的拒绝用户加入样本中，重新建立模型。

平常工作中主要用到以上两种方法，个人建议做申请模型最好做一下拒绝推断，这样模型上线后的得分分布和拒绝率和线下才不会有很大的差异。

6.模型转化为规则后决策点（cutoff 点）怎么设定？

规则只是判断用户好坏，而不会像模型会输出违约概率，所以设定决策点时需要考虑到规则的评估指标（精准率，查全率，误伤率，拒绝率），一般模型开发前会设定一个预期的拒绝率，在这个拒绝率下再考量精确率，查全率和误伤率的取舍，找到最佳的平衡点。

好的模型能接受更多的好用户，拒绝掉更多的坏用户，也就是提高好坏件比例，所以可事先设定一个预期目标的好坏件比例来选择最佳的决策点。

7.怎么做风控模型的冷启动？

风控模型的冷启动是指产品刚上线时，没有积累的用户数据，或者用户还没有表现出好坏，此时需要做模型就是一个棘手的问题，常用的方法如下：

① 不做模型，只做规则。凭借自己的业务经验，做一些硬性规则，比如设定用户的准入门槛，考量用户的信用历史和多头风险，而且可以接入第三方提供的反欺诈服务和数据产品的规则。另外可以结合人审来对用户的申请资料做风险评估。

② 借助相同模式产品的数据来建模。如果两个产品的获客渠道，风控逻辑，用户特征都差不多的话，可以选择之前已上线那个产品所积累的用户来建模，不过在模型上线后需要比较线上用户的特征是否与建模用户有较大的差异，如果差异较大，需要对模型做一些调整。

③ 无监督模型+评分卡。这种方法适用于产品上线一段时间后，表现出好坏的用户比较少，但需要做一个模型出来，此时可用线上的申请用户做无监督模型，找出一部分坏样本和好样本，用这些数据来做评分卡模型，当然这种模型准确性是存疑的，需要后续对模型不断迭代优化。

8.模型上线后是怎么监控的？

①前期监控（模型上线后一个月内）：

模型最后设定 `cutoff` 点后可以得出模型的拒绝率（线下拒绝率），上线后需要比较模型每日的拒绝率与线下拒绝率。如果两者差异较大，说明线上的用户与建模的用户分布有很大差异，原因可能是没做拒绝推断，或者用户属性随着时间发生了偏移。

监控模型整体的稳定性，通常用 `PSI` 来衡量两个时间点的差异程度。模型的稳定性是一个需要长期观察的指标，可绘制月/周 `PSI` 变化趋势图来分析稳定性的变化，从中可以发现用户是否随着时间推移属性发生了变化，以便及时对模型做出合理的调整。

变量稳定度分析，目的是如果模型的稳定性不好，可利用变量稳定度分析来了解是哪些变量造成的。对于不稳定的变量要分析其原因，并对模型做出调整，弃用不稳定的变量或者找其他变量来替换。

②后期监控（用户表现出了好坏程度）：

此时已积累了一些线上的好坏用户，可做模型的线上效果的评估，评估的指标有 `AUC`, `KS`, 基尼系数，如果模型的线下效果好，但线上效果却不理想，这个

模型是要做优化的。

好坏用户的评分分布。绘制线上好坏用户的评分分布图，如果符合期望（高分段好用户占比多，低分段坏用户占比多），则说明模型的线上的区隔能力较好。

变量鉴别力分析。用线上的好坏用户来计算变量的 IV 值，评价变量的预测能力，预测能力不好的变量可以考虑弃用。

9.怎么设计反欺诈模型？

反欺诈模型不太适合用二分类监督模型来做，一是诈骗的类型很多，是一个多分类的问题，不可能只做单一类型的反欺诈模型。二是大部分数据都是没有标签的，各种监督学习模型几乎无用武之地，而且区分噪声和异常点难度很大，甚至需要一点点想象力和直觉。三是欺诈类型不断在变化，如果用历史数据建的模型来识别之前从未出现过的欺诈类型，几乎是做不到的。

做模型之前需要确定两个问题，一是如何发现欺诈点，二是如何验证欺诈点。第一个问题可以用数据可视化的手段，做一下时序分析，或者用无监督学习来识别异常点。第二个问题可以用统计学的方法来验证异常点与总体是有显著性差异的，但有差异不一定是欺诈，所以需要与领域专家进行讨论，也可以直接叫来领域专家来分析用户哪些行为是欺诈的。

反欺诈规则+机器学习模型来检测欺诈用户，不能单纯依靠机器学习模型来检测欺诈。规则和模型用到的变量一般有：用户的设备，位置信息，关系网络，异常操作记录和第三方黑名单等。总之反欺诈模型难度很高，有相关经验的小伙伴可以互相交流一下。

10.当模型上线后发现稳定性不佳，或者线上的区分效果不好，你是怎么对模型作调整的？

模型稳定性不佳先检查当初建模时有没有考量过特征的稳定性，在模型前期监控一般会做变量的稳定性分析，如果发现稳定性不佳的变量，考虑弃用或用其他变量替代。另外可以分析下线上用户和建模用户的分布差异，考虑在建模时增加拒绝推断的步骤，让建模样本的分布更加接近于实际整体的申请用户。

线上的效果不好可以从变量角度分析，做一下变量鉴别度分析，剔除掉效果不好的变量，挖掘新的变量入模。如果一个模型已上线较长的时间，用户的属性

也慢慢发生偏移，建议重新取数做一个新的模型替代旧模型。

11.如何衡量一个风控模型的效果？

①评分卡建模之前的评估：

主要评估建模样本的稳定性，根据评分卡的目的不同，比较对象为总体或者近段时间的样本。

②分箱过程的评估

变量分箱的同时会计算 WOE，这里是对 WOE 进行可解释性上的评估，包括变化趋势，箱体之间 WOE 差异，WOE 绝对值大小等。

③对逻辑回归模型的评估

将数据集随机划分为训练集和测试集，计算 AUC, KS 及 Gini 系数，通过交叉验证的方法，评估模型的泛化能力，评判指标选择 AUC。绘制学习曲线，评估模型是否有过拟合的风险，评判指标为准确率（Accuracy）。

④转化评分之后的评估

对 score 进行可解释性的评估，评估原则与 WOE 评估大致相同。绘制评分分布图，观察分布的形状及好坏用户分布的重叠程度。绘制提升图和洛伦兹曲线，评估评分卡的可解释性和好坏用户区分效果。评估准确性，根据对精确率和查全率的重视程度绘制 PR 曲线，并根据业务目标设定 cutoff 点。

⑤评分卡上线后的评估

绘制评分分布表和评分分布图，计算评分的 PSI，评估其稳定性。

评估每个入模变量的稳定性。

12.在实际应用中，如何权衡模型的性能，可解释性和部署的难易程度？

首先要考虑到部署的难易程度，评分卡可以像普通规则一样在风控后台部署，但是像 xgboost 等比较复杂的模型需要考虑平台支不支持，一般来说能用评分卡解决的就最好用评分卡，部署简单而且可解释性好。然后关于可解释性和模型效果的权衡，个人认为模型的效果达到要求的情况下再去考虑可解释性，如果用评分卡做出来的效果不好，或者对风控的精度有更高的追求，但不那么强求可解释性，则可以考虑用集成模型或者神经网络等复杂的机器学习模型，只要你的

风控后台支持部署。

13.对于高维稀疏特征，或者是弱特征，你是怎么处理的？

对于高维稀疏特征，逻辑回归的效果要比 GBDT 好。这是由于逻辑回归的正则项是对特征权重的惩罚，以至于特征的权重不至于过大，而树模型的惩罚项主要是深度和叶子节点数目，而对于高维稀疏特征，10000 个样本可能 9990 个值是 0，那只需要一个节点就可以划分 9990 和剩下的 10 个样本，可见惩罚项之小，所以 GBDT 对于高维稀疏特征很容易过拟合。平时工作中如果用的是逻辑回归评分卡，则可以对稀疏特征进行离散化，离散成值为 0 或不为 0，再用 woe 进行编码。而如果使用 xgboost 等集成模型，最好还是不要用高维的稀疏特征。

弱特征指的是与目标变量关系不大的特征，或者是区分能力较弱的特征。在大数据风控中弱特征的种类很多，包括社交，通话，位置等信息，而且建模时弱特征会多达数百个。如果是用评分卡建模，弱特征一般会被舍弃掉，因为评分卡的入模特征数不宜过多，一般在 15 个以下，所以要找寻比较强的特征。而对于 xgboost 等模型，本身对数据的要求不是很高，并且精度好，一些弱特征进行交叉组合或许能给模型带来不错的效果。

14.对于成千上万维的特征你是怎么做特征筛选的，如何保证其模型的可解释性和稳定性？

可先做特征的粗筛选，例如缺失率高，方差为 0，非常稀疏的特征可以先剔除。

根据变量的稳定性再次进行粗筛，衡量指标有月 IV 差异，两个时间点的 PSI 差异等。根据 IV 值的高低筛选变量，或者直接用集成模型的特征重要性进行筛选。为了保证模型的可解释性，需要将共线性的特征剔除。

最后考察各个特征与目标变量的关系，要求在业务上有良好的可解释能力，并且特征与目标变量的关系最好是呈单调线性变化的，这样也能保证模型的稳定性。

最后可以考虑基于模型重要度的方式做特征筛选（比如基于树模型）

15.如何根据风险因素对用户分层，构建客群差异化的模型？

做客群差异化模型之前最好做一下用户画像，在风控领域中做用户画像的目的是：系统性的梳理用户群体，找到异同点对用户进行划分群体，分类的维度很多，可以是静态属性，购买偏好，也可以是褥羊毛党等风险属性。便于更深刻的理解业务，理解用户需求，风控离不开业务，只有深刻理解业务后，才能发现更多潜在的风险。便于后续的数据挖掘，了解坏用户的行为特征，并且根据用户特征做关联规则分析。对不同类型的用户，做针对性的风控规则和风控模型。

平常工作中的做法：对用户做静态属性的划分，比如按性别，年龄，收入，职业等。例如刚毕业工作的年轻人和收入比较稳定的中年人，他们的借款需求，风险程度就不一样，可以先对用户群体做这样的划分，再对每个群体单独建立模型。

根据用户风险属性做差异化模型，例如对手机分期业务做一个套现风险模型，挖掘套现风险属性，目标变量变成是否为套现用户。

16.额度，利率的风险定价模型你是如何设计的？

首先做风险定价模型需要熟悉产品的属性和特点，像小额现金贷和大额分期贷两种产品的额度定价逻辑就不同。另外也要了解产品的盈利模式和预期的利润，这点需要与业务部门做好沟通，通常关于额度，利率也是业务或者产品制定的。

风险定价模型一般采用评分卡模型，最后设定 cutoff 点后对通过的用户进行风险等级划分，对于风险高的用户给的额度较低，或者利率较高。一般来说中低额度的用户占大部分，高额度用户占小部分，最后可以得出一个平均额度或利率，这个值事先可以根据预期的利润/资损来计算。

17.风控流程中不同环节的评分卡是怎么设计的？

申请评分 A 卡用在贷前审核阶段，主要的作用是决定用户是否准入和对用户进行风险定价（确定额度和利率），用到的数据是用户以往的信用历史，多头借贷，消费记录等信息，并且做 A 卡一般需要做拒绝推断。A 卡一般预测用户的首笔借款是否逾期，或者预测一段时间内是否会逾期，设计的方式也多种多样，

有风险差异化评分卡，群体差异化评分卡，或者做交叉评分卡等。

行为 B 卡主要用在借贷周期较长的产品上，例如手机分期。作用一是防控贷中风险，二是对用户的额度做一个调整。用到的数据主要是用户在本平台的登录，浏览，消费行为数据，还有借还款，逾期等借贷表现数据。

催收 C 卡主要是对逾期用户做一个画像分析，通过深度挖掘用户特征，对逾期用户进行分群，做智能催收策略等。

18.芝麻信用分的主要计算维度？

主要维度：

个人属性：职业类型、学历学籍等

稳定性：手机稳定性、地址稳定性、账户活跃时长等

资产状况：账户资产、有无住房、有无车辆

消费能力：消费金额、消费层次、消费场景丰富度

社交情况：人脉圈信用度、社交广度、社交深度

信用历史情况：信用历史时长、信用履约记录数、信用履约场景、公共事业缴费记录

违约历史情况：违约场景数

19.如果用 `borderline_smote` 会不会导致某一箱内坏的比例过大呀？

应该是 `badrate` 越高的箱插的越多，从而差异最大化

20.有什么好的模型调参的方法么？网格搜索？贝叶斯优化？

$\text{offks} + (\text{offks} - \text{devks}) * 0.8$ 最大化。这个 0.8 自己来调整，看你是希望跨时间验证集上的 KS 更高，还是希望模型更稳定。然后模型内部的参数搜索建议贝叶斯优化，推荐原因是因为快一点。精度其实差别不大。然后精细化调参，一般都是千分位上的提升。

21.U 型特征怎么转化为单调？

转化成中值差值的绝对值。

22.什么是 baviar 图?

横轴特征升序，纵轴 badrate

23. 采样怎么做效果才会好?

数据集清洗了嘛，还有特征呈线性了嘛，这两个不满足过采样很难保证效果的，通常 xgboost 不保证线性也行，但是要用 smote 最好做一下。

24.什么我们做评分卡的时候要用 woe 编码，而不是用别的编码方式呢？比如 onehot 之类的，仅仅是因为 woe 可以把特征从非线性变成线性的吗？

因为 onehot 后高维稀疏，模型学习是有困难的。一般模型会做 embedding，但是做了 embedding 就不可解释了。所以用 woe 来代替。

25.深度学习的风控模型，从经验上看，样本量大概要多少条啊

不同的模型不一样，而且也不光要注意样本量，比如 RNN 其实希望序列长度至少在 12 个月以上，粗略的说，样本量五十万以上效果比较好

26.分箱后，各箱 badrate 单调递增从业务上怎么理解呀？

我们有个先验知识，多头越多 badrate 越大，历史逾期越多 badrate 越大...等等，如果变量分箱后不符合这个先验，可能就把他剃掉了。

27.我这更换了数据源 现在有标签的样本只有一万过条 有什么方法建议的吗？

一般先建议做一下过采样，负样本均衡一下

28.5 万正样本，200 负样本，B 卡，不只是提高额度，会拒绝一部分客户，怎么建模？

5 万负样本是没有做下采样的必要的，200 正样本无论用什么方法做过采样说实话由于自身携带的信息量比较少，学习的应该也不是完全的。

所以这时候建议先略作改动，评价函数加一项，负样本的召回率，也就是说

这时候不是主要关注 KS，而是对负样本究竟能抓到多少，然后负样本学习的时候一定要加权，权重就按照 sklearn 中逻辑回归默认的 balanced 方法就 ok，而且如果是我可能生成一个决策树，把坏账从 0.4% 下降到 0.12% 左右我觉得就蛮好的了。

29.leader 给我的任务是对短信打标签，也就是判断出短信属于的标签是哪一类，这样一个任务是提取文本关键词的任务吧？

我建议先确定每个词对每个类别的贡献度。简单来做就是每种类别找几个词，手动划分一下有这个词，就属于这个类别。复杂一点来做，就训练个模型，确定每个词对每种类别的贡献度，然后对每条记录做个预测，排名前几的标签都给他。

30.简单的除了之前说的那种统计坏的词，然后正则匹配的还有其他的吗？leader 之前说拿到词的重要度，是在整个语料中的一个重要度的话，tf-idf 是不可行的，现在要出一个版本的话，您有什么建议吗？

首先需要每篇文档的标签，然后去找词的重要度，不然只能拍脑袋呀。

然后想知道每篇文档的标签，你们可以先用之前的方法挑选一些特别明显的词。给文档打标签。然后这样迭代着做。

31.请问欺诈标签如何定义？

这是一个仍在不断尝试的部分。现在使用的方法：外部黑名单，客服的反馈，明显坏的行为（例如贷款逾期 M3+。通讯录造假），根据已有标签进行染色，负样本上聚类（已有标签明显多的一类）

32.最近面试数据分析师岗位，和算法岗有什么不一样么？会提到数据敏感，究竟应该怎么回答？

区别是分析师是业务+报表+算法，工程师是业务+算法+工程。数据敏感是玄学，关键要知道数据怎么分析，你告诉他，数据要对比着分析，随便拿出一个值就知道这个值是什么水平还是比较困难的。

比如我们分析模型表现，分析变量稳定性。不是给出一个月份的分布我们就知道模型好不好，而是要两个月作对比才知道。

33.现在公司是不是先准入规则，然后再进入一个 pre-A 模型，然后再是反欺诈模型，然后是 A 卡之类的？

可以理解成模型是嵌在规则里面的，规则到处都有。

34.准入规则，pre-A，反欺诈规则反欺诈引擎，还有风控模型，一般都不会选用相同的特征？因为客户群体会越来越少

也是不单单这个场景才有的。基本上每个机器学习模型或多或少都会遇到这种问题。一般是不会用相同的特征做重复筛选的。这样会导致样本偏移更严重。

就是说，被拒绝的人，是由于某些特征表现差，被拒绝的，那随着时间推移，下次建模的样本里面，就没有这些人了...这些这些特征上的样本分布就变了。

35.用三种标签学出来的三个模型，从三个维度给一个人的欺诈风险打分，怎么给这三个模型进行融合，因为单个用户申请线上预测，无法根据客户在各个模型排名取平均。但这三个模型的输出的概率区间又是不同的，比如模型 A 的输出区间是[0-0.4]，模型 B 输出区间[0-0.9]，也不是正态分布，zscore 标准化不能用，只能 MinMax 先进行标准化？再进行分数融合？

对的，一般要 minmax，规约到一样的范围内

36.在风控场景下，有时候我们会对用户行为序列建模，那在使用 BiLSTM 对用户行为进行建模时，神经网络的输入层是什么？输出层是什么？怎么把用户行为数据转换成神经网络输入层的向量？

打个比方啊，额度使用率按照月份的时间序列就是，前 0-30 天的额度使用率，前 30-60 的额度使用率，前 60-90 的额度使用率...变成一个列向量。有多少特征（额度使用率是一个特征）就有多少个列向量。然后输入层就是这些列向量，输出层一般就是用户的标签。最终可以把输出的 score 丢进逻辑回归，或者把中间测参数拿出来也可以。

37.在 xgboost 或者 lightgbm 建模之前是否进行相关性处理，去掉相关性较高的变量？

要的。lr 中我们是为了对向量空间描述的最好。在 xgb 主要是想去掉相互替代性较强的特征。

比如一个特征给他找相关性特别强的 9 个特征放在模型里面，存成不同的名字，你会发现他本来重要性是 10，每划分一次，一个特征就比另一个好用那么一点，这么弄了之后十个特征的重要性都变成了 1，然后被我们用 `feature_importance>5` 给筛掉了.....这多尴尬

38.在评分卡上线以后。进行监控的时候，监控的周期是多少，是将新数据下载到本地来计算 ks、psi 以及变量稳定性等这些指标吗？

一般有日报周报月报，看客群量大的话，周期可以短一点，量少的话，计算指标没什么意义

39.不平衡场景下的过采样（朴素、SMOTE）后训练的模型都需要结果概率校正吧？如何操作？

只有单个模型不需要做校正，如果需要和其他模型做融合或者做比较的时候可以做

40.请问回归决策树针对离散变量使用，是否先转成 one-hot？否则 1) 如果是没转码的字符变量。直接报错 2) 如果转成数值。就会把我们的编码，当做连续变量进行回归处理？

正常是要做 onehot，但是特征高维稀疏，还需要做 embedding，这样就没有解释性了，所以个人建议可以做 WOE，或者按照每个取值的 badrate 做一个排序然后 labelencoder

41.比如说在建模的时候，有一个特征是性别，我是应该在男和女情况下建立两个模型 还是 将性别放进 x 里建立一个模型

个人一般都是放进 x，电商推荐里面男女买的东西不一样所以会拆开，贷款这件事情，差不多吧

42.对于分期账单，在进行逾期分析的时候，是以每个到期用户的第一期来计算，还是以每个到期用户的最近那个到期来计算，还是按照账单每一期来计算？现在就是出现有些用户，第一期没有逾期，但第二期就会逾期或者不还这种就是把每一期当做一个账单或者一个人，然后进行分析？

如果大家都有很多期的话，尽量做每一期的。不是的，每一期当作一个人不太合理，如果想做的严格一点，可以选最大逾期作为标记。

43. $KS \text{ 值} = \max(TPR - FPR)$ 的说法对吗？怎么图形和公式都和上课老师讲的很像，这个公式可以在 KS 曲线上求出来，通过改变概率阈值。KS 值和 KS 曲线通过调节概率阈值，得出的 KS 值是一回事吗？

当箱分的足够细的时候应该是一回事，一般箱分的越多 KS 越大咩

44.计算模型的 psi 一般用等频分还是等距分？一般分几份？

通常都是等频，个人一般分十箱

45.lgb 在不平衡分类上训练了一个模型，训练集上输出概率分布呈偏态分布（偏向 0，好样本），但在测试集上呈近似正态分布。如果设置 `pos_scale_weight` 参数，会产生这种情况，如果不设置，测试集上的概率分布还是和训练集类似这种现象正常吗？

正常，`scale pos weight` 相当于改变了训练集的标签分布，不过我理解，输出概率分布不一样，对排序模型没有影响吧～，只不过和别的模型的分数不能直接比较。

46.如何标记客户好坏的？

可以说迁徙率

也可以说逾期天数作为标记好坏的依据

因为本身样本不均衡，会偏向扩充坏人的数量（比如以 `pd1` 来标记好坏，坏人肯定比 `pd15` 会多很多）

注意很多公司建模的时候，去除一部分灰色客户（比如去掉 `pd1~pd5` 的客户）

39.做模型时用到了哪些数据源？

征信数据

运营商数据

埋点数据

平台自有数据

用户手填数据

数据有很多，每家都各有不同，小心点也可能问你数据来自哪家平台哦。

很多小型公司都喜欢用运营商数据，因为便宜，很多都是免费的。

46.你们模型是怎么部署上线的？

最简单的，把评分卡每个区间加多少分减多少分，怎么做映射的逻辑，讲给开发小哥，他会帮你在线上写 `if else`

生成一个 `pmml` 文件，给开发小哥调用

公司自己做的决策引擎，或者是租的，自己写变量逻辑上线

用 `flask` 或者 `Django` 自己写接口上线

47.xgb 变量重要性用哪一个指标？

通常会直接用 `weight`，他们筛选出的变量略有区别，但是使用下来区别主要在于重要性最低的那几个可以互相替代的特征，具体用谁其实并不重要。经验告诉我们 `total_gain` 效果可能会略好。

是的，`xgb` 筛选特征，然后用新的特征建模，但是通常不建议筛选后还用 `xgb` 建模，这不符合模型融合的策略。

xgb 其实是没法解释的，如果希望有逻辑回归的可解释度，建议相同数据、相同变量，带入 lr 建立一个陪跑的模型，寻求解释的时候去 lr 中找原因。特征相同的前提下，不会有太大出入的。

xgb 筛选特征可以理解为用均方差最小来做特征筛选，和 IV、WOE 属于同一种筛选方式，描述的都是特征对分类任务的贡献度，一般用一个就行了，每个人的方法都不一样，见仁见智。

48.如果我们做完模型，只是一个人逾期的概率，那不同的人还有不同的额度和手续费，我们直接对最终收益进行建模那多好？？最大化收益不就是我们的业务目标么？

事实上我们的策略是不停的调整的，如果想计算最终受益，然后建模的话，以后上线了这个模型就必须固定策略不能变，不然稍一改变，这个模型就不适用了，这显然是不符合我们实际业务的，所以我们都是固定模型，让策略来调整，最终达到一个比较好的收益。

49.什么是多头借贷？

多头借贷，即单个借款人向 2 家或者 2 家以上的金融机构提出借贷需求的行为。由于单个用户的偿还能力是有限的，向多方借贷必然蕴含着较高的风险。一般来说，当借贷人出现了多头借贷的情况，说明该借贷人资金需求出现了较大困难，有理由怀疑其还款能力。

50. 模型开发中，one-hot 编码好还是哑变量编码好？

在风控的场景下，woe 好，有助于后续评分卡的构建

51. 市面上很多数据机构，特征变量时间用累计的，30 天，90 天，180 天这样累计的，尤其是一些多头申请数据。那这样是不是意味着特征衍生是不够专业或者还存在缺失的。

不会，一般这都是他们筛选过后较稳定有效的特征表示形式。

52. 模型的 ks 和 auc 有多少可以上线了？一般训练集和测试集之间的 ks 和 auc 相差多少算是比较合理的呢？

KS 至少 20%，不然和瞎猜没啥区别。业内都认为训练集和测试集之间的 KS 相差 5 个百分点以内才算没有明显过拟合。

53. A 和 B 相关性强，B 和 C 相关性强，这种情况去除哪个变量？

去掉 VIF 最大的或者重要性最低的。

54. 关于缺失值处理。您提到，某些变量不应该处理，标记出来即可，我理解这是针对分类变量。假设类似芝麻分，缺失了 60%，但剩下的 40%依然能看出 KS，这时候除了做是否确实芝麻分的衍生外，也想保留芝麻分的数值型特征，但此时使用中位数，或者平均数，填充，其实都会严重影响 芝麻分的分布。不知道，您是怎么处理的？

先搞清楚为什么缺失，通常会默认缺失的属于同一类，如果确认只是随机缺失的话，可以分别尝试一下各种填补看看哪个效果最好，刚刚 tom 提到的极大似然也可以尝试一下

55. 现在做 xgb 模型还需要分箱编码嘛？

xgb 有些做的，比如城市这个变量取值比较多，用 woe 指定一下分箱，牺牲一些精度来增强鲁棒性。

56. lr 那种模型里变量分箱编码以后都是单调齐次的了，树模型并不需要这种性质是不是及时树模型做了分箱也没必要分的很少几个 bin 弄成单调的，只是分几个箱防止过拟合就可以了？

正常是这样的，我之前做过一家是 线上 xgb，线下 lr，解释性的问题用线下的 lr 来说明，所以要在 xgb 前面做 bivar，为了保证 xgb 和 lr 的变量完全一致的。

57. 分箱法的主要目的？

由于分箱方法考虑相邻的值，因此是一种局部平滑方法。分箱的主要目的是去噪，将连续数据离散化后，特征会更稳定。

58. 请问类似特征 “近 30 天通过率”，出现空值的情况应该怎么处理？这是因为用户近 30 天没有申请。补 0 的话，会和用户有申请但没有通过件这样的情况混淆。补其他值感觉也不符合业务逻辑。

这种应该单独赋值的，后面分箱也尽量不要和别的放在别的箱里面

59. 要是公司里做 lgb 的 A 卡，我搓出来几千维特征模型重要度都 >0 ，这种模型能用吗？

可以用，不过要关注一下稳定性。也见过线上模型变量近千维的

60. 请问无监督做特征选择都有什么方法呀？

autoencoder

61. 做特征衍生的时候 经常会衍生出不稳定的特征（训练与测试集上分布相差比较大） 有没有什么自动化的方法可以帮助剔除和检验出这些特征呢？

单变量 PSI 值算是最自动化的了，bivar 图可能不太自动化，需要你扫一眼。

62. 下探一般要选多少样本进行下探？下探的样本评分很低，但选取哪些呢？

按照期望得到的坏客户量进行选择。不知道下探后会收获多少坏样本对不对？上一次模型迭代时候的测试集模拟就派上用场了。用那个百分比作为下探区间的预期百分比，然后去算吧。

63. 训练出来的模型如果出现了误判的情况（假正和假负），应该怎样去让模型学到这部分误判的情况，而后正确的预测呢？一般是怎么操作的呢？

算法来说这就是 adboost，然后有个东西叫做 bad sample 分析，就是针对错

分样本来分析为什么错分。具体百度。

64. 实际分箱过程中如果用等频分箱，怎么使得每箱都有好坏样本，保证后面计算 WOE 有意义？

等频分箱之后，每一箱坏样本占比不同才有趋势呀，主要还是看趋势，也就是说等频分箱后，要在根据好坏样本占比来合并初始的分箱，手动合并的话一般保持单调趋势就行了，自动的话，可以考虑把相邻两箱 IV 值的差，小于某个阈值则合并为一箱

65. 地址数据具体怎么用比较好？

最近好像是提取城市、省份、经纬度，以及房价信息

66. 计算模型的 psi 一般用等频分还是等距分？一般分几份？

通常都是等频，个人一般分十箱

67. 不平衡场景下的过采样（朴素、SMOTE）后训练的模型都需要结果概率校正吧？

我理解只有单个模型不需要做校正，如果需要和其他模型做融合或者做比较的时候可以做。

68. feature_importance 和 iv 有时候选出的变量差别很大，该以哪个为准，怎么判别

IV 和目标函数的关系更大，但是一半用 IV 做初筛，iv 很低，不用进模型，但是 IV 是单个变量的作用，而 feature_importance 有一个特征组合效应在里面。所以按理也可以推出，不一定是选 IV 最高的变量组合在一起就一定能够 ks 最高，而是特征组合在一起综合效应最高的才是 KS 能够达到最高的。

69. 怎么解决测试集上 auc 偏低的问题？我这个数据集比较小，训练集有 1000 个，是前 20 天，测试集有 200 多个，是后 10 天，这个是纯多头数据，原始多头变量 120 个，自己做衍生变量到 7000 左右。训练集违约率 20%左右，测试集违约率 14%左右。

太小了，感觉模型学不到什么的，应该不会有太明显的改善的，做个单变量分析看看比现有特征的强弱就可以了。

70. 如果客群风险发生变化，会怎么做？是不是

1) 看变化前后用户特征(重要特征)的分布是否发生变化

2) 是不是有欺诈的可能

3) 如果以上都不是，是不是需要调整准入规则或者申请模型。

对的，一般不是欺诈就是该迭代了

71. 一般在业务中哪种分箱用得更多啊？

一般用基于 iv 或者卡方的自动分箱

72. 现在市面上在金融风控中用的无监督算法都有哪些？

主要是基于图的离群检测和聚类，其次还有孤立森林，LOF 这种，还有通过聚类进行特征衍生

73. 利用 rf 看特征的重要性，碰到了类别型的特征，是直接做 one_hot 处理还是分箱转为 woe，或者不参与特征的排序

一般 woe 效果比较好

74. 构建一个申请评分卡需要多长时间，就是从数据库选择数据、拉取数据，到最后生成一个评分卡需要多久，然后部署上线稳定运行又需要多长时间？

最慢能一个月，别人给上线得排期，还得慢慢核对变量逻辑，最快能一两天，

自己开发自己上线

75. 有 30 天的放款表现数据，其中有不连续 10 天的用户逾期率较低，有不连续 20 天的用户逾期率较高，那么一般是什么原因造成，该怎么找到造成这样的原因？

跟业务发生的时间线对一下看看吧，我理解这个是需要分析一下的，可能对完了发现是哪个渠道不好，或者是量比较小导致的偶然现象。

76. 进行线性相关性和多重共线性检验的时候，特征是用原始特征还是 WOE 编码后的特征呢？

woe 编码后的。

77. 对于评分卡模型，是先特征选择还是先对特征进行分箱处理？对于特征非常多的情况下，分箱的效果也不太好，我就考虑是不是先对特征进行选择再处理呢？

是这样的，分箱是单特征之间进行的，和特征多少是否筛选没有关系。

分箱的时候首先考虑用什么算法。lr 必须做分箱，不然鲁棒性会很差。xgboost 做了，稳定性上升，准确度下降，有舍有得。lightgbm 绝对不要做，直方图算法加上分箱对性能影响比较大。

然后分箱分两种情况，一种是对连续变量做分箱，一种是将字符变量做合并。前期粗分箱通过等频和 IV（卡方）进行划分。后期通常根据 bivar 图来确定。

建议，类别变量统一做 woe 处理。省心效果还好。

78. 对于信贷评分卡模型 数据量一般在多少范围比较合适？

首先合适的样本量和预计入模特征数量有关系，模糊的说，可能是 5000 一档，5 万一档，50 万一档。5000 档以下模型不稳定，负样本通常非常少。5000-5 万档模型逐步稳固，特征通常不超过样本的百分之一，lr 相应的要用更少的特征。5 万到 50 万感觉提升不明显，更多的是对正样本做下采样，进行均衡学习。50 万以上深度学习效果突出。

79. 小微正常过反欺诈，主要考虑哪些？

信用风险，行业情况。挺多的，比如，发票流水进项，销项 的金额、频次，和时间以及传统统计指标 做笛卡尔乘积，还有行业指标，区域指标，企业间销售关系，专票循环网络造假骗贷等。

80. 我们的模型基本上都是基于样本不均衡的数据的，那么问题就来了，特征工程里不做采样处理的话，样本是极不均衡的，那么做出来的模型有的时候也会失真。如果做采样的话，那么虽然模型有保证了，但是训练模型的好坏分布并不符合线上的实际好坏分布。这个问题怎么解决呢？

我们是把采样权重记录下来，不参与模型训练，只作为计算 KS 和最终模型模拟时候的权重。然后测试集是没有做采样变换的，所以直接就是真实的

81. 如果采样特征完备性比较好，是不是采样全中就不需要考虑了。或者这个权重怎么把它和 ks 计算结合起来？

因为采样后的训练集这张表长得会不一样嘛，所以会把权重丢进去，就是算样本数量的时候，再乘以一个权重。

82. ks 指标计算，会考虑这个权重吗，还是继续使用采样过后的？

训练过程里面，训练集我是没有考虑还原的，只是最终报告里面还原成真实的了

83. neo4j 上线，实时构建图谱的性能如何？

实时性问题基本上可以达到一秒以内一个用户。2 亿节点，5 亿关系。

84. 无监督与 xgboost 结合的反欺诈模型该如何做？

首先聚类，得到每一个簇的聚类中心，然后取出所有的聚类中心，对这些点进行异常值检测（本质是在对簇做异常簇检测）。比如说放进孤立森林中，得到异常值作为整个簇的异常值，带入 xgboost 进行训练。

85. 根据业务构造损失函数，能举个例子么？

为业务定制损失函数，说起来高级，其实很简单的。假设现在有一个 preA 模型，用处是拒绝 5% 的客户，那么他的损失函数也使用 AUC，并不能保证捕获率足够大。所以可以改写一个优化捕获率的损失函数，只要保证是凸函数或者满足使用算法的优化条件就行。

86. 催收主要工作就是失联修复，本质上是催收成本与收益的平衡，过程中需要考虑安全与体验性，这样说对吗？

催收工作的直接目的是回收逾期账款减少不良产生。长远目的是改变债务人的还款习惯，让债务良性循环。

这里有个前提概念需要清楚的是，信贷本来就是为有还款能力的人提供适当超前消费服务的，并不是为没有还款能力的人应急用的，所以目前的市面上的绝大部分信贷产品的产品设计出发点是有一定偏差的。存在即合理你知道就好，反正一时半会儿也无法改善。

催收成本与收益的平衡和过程的考虑安全性与体验性这句话是没错的。可以这样来理解：催收成本包含了很多，最大一块就是人力成本，解决人力成本是催收的未来出路，所以自动化催收工具及智能催收是市场的主流研究方向，只是现在仍旧处于初级阶段，本质原因是合规问题。

因为样本少，无法通过常规的方法论得到想要的预测结果，这就会导致一个奇怪的现象，每家都有 C 卡，但是每家 C 卡的请开给你只对自己的案件有效果，平移同类就没办法保证预测结果，或者随着时间的推移自己的 C 卡结果都会有很大程度的波动。

这是一个方面，但是说回来如果为了回收账款导致支出过大是完全不可取的。

通常解决办法有两个，一个是用其他的盈利去补贴（一些股份制或者大行有自有催收团队的都会这么做，具体做法很多可以脑补充，可以说只有想不到没有做不到）。

一个是采用外包（这里包含人力外包或系统外包）所谓安全和体验安全是指客户信息数据的安全合规合法、体验是客户体验，因为获取客户的成本很高很贵

所以一般银行做法都会有交叉营销或者客户重复利用。典型的如平安。

87. 催收策略是如何设计、优化，具体怎么制定及优化催收策略。策略规则在决策引擎中是怎么测试及部署上线的？

用业务的理解参考

催收策略一般都会有 2 套以上，后台的运作一般都是同时运行，比如进入策略的的案件 100 个，一般会 3: 7 或者 2: 8 开，少的部分就是测试，多的部分就是常规。通过产生的两组不同数据进行监控效果，如果少的部分效果比多的部分好和稳定那么就会逐步替代多的部分作为主要运行，如此更迭。算法上决策树和 xgboost 都是比较常用的办法。

实际就是关键区分指标要找到。举个例子。我们在做经济复苏模型（哪些人在未来会还款）关键指标选择调整的时候有一条对于设备安装 APP 的种类作为关键指标，我们选择了母婴类 APP 作为关键区分项效果很好。乍一看感觉和还款没啥关系，但是实际想想不难推测为什么这类人未来还款会很强。

这类 APP 如果不是刚性需求是没有人会安装的。即使出厂有安装也多半都会被卸载。反过来忽然有需求那么一定说明经济状况还不错家庭情况也相对稳定才会考虑哺育后代的。所以这也说明安装这类人的经济情况已经好转。

以上的情况可能比较跳跃但是我想说的是关键的指标调整除了一些常规的什么申请次数之类的也要多想想一些被拆分的很碎的指标的衍生用途。多尝试。

另外接触比较多的一线的催收人工策略就是诸如什么时候打电话，什么时候发信息，要怎么个频率。以及话术的一些应用的策略，这个没有什么算法，都是通过在线的案件表现和最终的效果进行积累和调整的，这个应该不在你的工作范围中，不过建议有空可以多和一线管理人员交流看到真实的表现这样对你的催收策略调整设计都很有用。

（如何设置规则方法论:市面上常见是通过决策树算法（聚类分析）得出，平衡其触发率和命中率还是要通过风控指标的监控进行调整.）

88. 评分卡做好以后，先在原有基础上等上一段时间，积累一定的数据量，然后再将积累的数据和线下的评分模型比较；那么我上线以后，在通过一些指标监控的时候，什么样的情况下模型变得不好需要重新调整，什么样的情况下模型良好而不需要调整？

一般有套完整的监控体系，监控 PSI KS capture_rate 超过一定阈值就可以 refit 或者 rebuild 了。

89. 怎么更新评分卡或模型，比如通过决策规则获得数据构建评分卡或模型，上线一段时间之后，想更新模型，该用什么数据去建模

refit 也就是用最新的数据来建模，rebuild 就是按照之前的逻辑重新做一次。