

1. 说一下 KNN、K-Means 区别

KNN 是分类算法，它是监督学习，知道了结果去效验结果是否正确。K-Means是聚类算法，它是非监督学习，它需要先自己算去一个结果。

答案解析 考察分类算法和聚类算法的区别



2. 如何不用自带函数统计一段话每个单词出现的次数

```
sentence = 'xxx xx x' words = sentence.split() dic = {} for w in words: if w in dic: dic[w] += 1 else: dic[w] = 1 for w, cnt in dic.items(): print('单词%s出现%d'%(w,cnt))
```

答案解析： python 能够便捷地处理文本相关的问题。

在统计词频时，首先将语句拆分为一个个单词，然后将单词写入字典并统计每个单词出现的次数，最终输出即可。对于有大小写的情况，可以先用 lower 函数统一转成小写后进行统计。

9. 商城每天的人流量属于什么分布？泊松分布和二项分布的关系？

参考回答 泊松分布。泊松分布是二项分布的近似，当二项分布的 p 很小，重复试验次数 n 很大时，两者分布接近。答案解析 二项分布指已知某件事情发生的概率是 p ，那么做 n 次试验，事情发生的次数就服从于二项分布。泊松分布是指某段连续的时间内某件事情发生的次数，而且“某件事情”发生所用的时间是可以忽略的。商场每天是一个连续的时间，如果把每一天分割成无数的小份，那么每一段时间内发生的事件都是独立的，在一个极小的时间内，人们进出的概率为 p 。那么在一天内，就有 n 次发生人们进出这个事件。而当 n 很大， p 很小，二项分布计算概率的公式会趋向于泊松分布。

11. 随机误差的分布

参考答案 正态分布（高斯分布）答案解析 根据中心极限定理，大量独立的随机变量之和趋向于某个稳定的分布，该分布后来被人们称作正态分布（高斯分布）。人们认为误差是随机的，所以误差的和服从正态分布。



12. 简单说一下两类错误

参考答案 第一类错误 α 叫弃真错误或显著性水平，即原假设为真时却被我们拒绝的概率；第二类错误 β 叫采伪错误，即原假设为伪我们没有拒绝的概率。在一定样本量的情况下，减小一类错误必然会增大另一类错误，在实践中我们一般会优先控制第一类错误，因为原假设是非常明确的 答案解析 1-第一类错误也即原假设为真的情况我们接受的概率，对于 A/B 测试，犯这个错误代表新策略没有收益，我们却认为有收益，然后上线的错误，一般第一类错误不超过 5%，第一类错误是明显的，也就是说在原假设为真的情况下接受原假设的概率要超过 95%；统计功效=1-第二类错误，也即当 AB 两组实际有差异时，能被我们检测出来差异的概率

17. 作为出行领域的小玩家，司机端的订单构成是什么样的？头部优秀司机聚集

大量订单，还是订单分布比较发散。

参考答案 若为较成熟健康的体系中，应为后者；在初期时为前。
答案解析 在较健康的供给端体系中，司机端的订单构成应为倒三角或者菱形分布，即头部和腰部司机的订单较多，尾部的订单较少；而在初期时则是头部效应明显，订单集中在头部，后期随着司机和订单量的增多，不可能由头部司机撑起大部分订单的。