

1、解释数据清洗的过程及常见的清洗方法。

数据清洗是指在数据分析过程中对数据进行检查、处理和纠正的过程；是数据预处理的一步，用于处理数据集中的无效、错误、缺失或冗余数据

常见的清洗方法包括：处理缺失值、处理异常值、去除重复值、统一数据格式等。

处理缺失值：可以删除包含缺失值的数据行，或使用插值（如均值、中位数或回归模型）进行填充。

处理异常值：可以使用统计方法（如 3σ 原则或箱线图）检测异常值，并选择删除或修正异常值。

处理重复值：可以检测和删除数据集中的重复记录。

处理格式错误：可以使用字符串处理函数或正则表达式等方法来处理格式不正确的数据。

处理不一致的数据：可以进行数据转换或归一化，使数据符合一致的格式和单位。

2、什么是缺失值（Missing Values），如何处理缺失值？

缺失值是指数据集中某些观测值或特征的数据为空缺的情况。

处理缺失值的方法有：删除缺失值、填充缺失值（使用平均值、中位数、众数、插值等方法填充）、使用模型进行缺失值预测填充等。

删除缺失值：如果缺失值的比例很小，可以考虑将包含缺失值的数据行删除。

填充缺失值：可以使用均值、中位数、众数等统计量来填充数值型特征的缺失值；对于分类特征，可以使用出现频率最高的类别进行填充；对于时间序列数据，可以使用前后数值的插值进行填充。

预测填充：可以使用机器学习算法（如随机森林、KNN 等）预测缺失值进行填充。

3、解释一下数据归一化和标准化

数据归一化和标准化都是将数据转换到一定的范围或分布上的方法。

数据归一化（Normalization）通常将数据缩放到 0 到 1 的范围内。最常见的归一化方法是使用最小-最大缩放（Min-Max Scaling），公式为： $(x - \min) / (\max - \min)$ ，其中 x 为原始值， $\min$ 为最小值， $\max$ 为最大值。

数据标准化（Standardization）将数据转换为均值为 0，标准差为 1 的标准正态分布。标准化可以通过减去均值、除以标准差来实现。标准化后的数据具有零均值和单位方差，更适合某些机器学习算法的使用。

4、什么是异常值（Outliers），如何检测和处理异常值？

异常值是指与其他观测值明显不同的异常数据点。

异常值可以通过统计方法（如箱线图、Z-score、 3σ 原则等）和机器学习算法（如孤立森林、LOF 算法等）来检测。处理异常值的方法包括删除异常值、替换为特定的值或进行修正等。

统计方法：如基于均值和标准差的 Z-score 方法，将与均值相距较远的数据视为异常值。

箱线图：根据数据的分位数范围判断异常值，超出上下界的数据被认为是异常值。

机器学习方法：如孤立森林、LOF（局部离群因子）算法等，基于数据的密度和距离来检测异常值。

处理异常值的方法包括删除异常值、替换为特定的值（如均值或中位数）或使用插值方法进行修正。

5、你使用过哪些数据可视化工具和技术？

包括但不限于：

数据可视化工具：Tableau、Power BI、matplotlib、ggplot 等。

编程语言：Python、R、JavaScript 等。

可视化技术：折线图、柱状图、散点图、饼图、热力图、地图可视化等。

6、什么是关联规则（Association Rules）分析？如何使用它来发现数据中的关联关系？

关联规则（Association Rules）分析是一种用于发现数据中的关联关系的技术。它可以通过挖掘数据集中的频繁项集和关联规则包含两个部分：前项（Antecedent）和后项（Consequent），它们之间用箭头表示。规则的形式通常是“前项 $\rightarrow$ 后项”，表示前项的出现与后项的出现有一定的关联。

关联规则发现的过程包括以下步骤：

扫描数据集，统计每个项的出现频率，找出频繁项集。

根据频繁项集生成关联规则，计算规则的支持度和置信度。

根据支持度和置信度设定阈值，筛选出高置信度的关联规则。

关联规则的支持度（Support）表示在数据集中同时包含前项和后项的概率，置信度（Confidence）表示在出现了前项的情况下，同时出现后项的概率。

关联规则分析可以应用于许多领域，例如：

零售业：可以发现购物篮中的关联商品，进行交叉销售和商品搭配的推荐。
金融领域：可以发现不同金融产品之间的关联关系，进行个性化的理财建议。
营销领域：可以发现用户行为和用户属性之间的关联关系，优化营销策略。

7、解释一下线性回归 (Linear Regression) 和逻辑回归 (Logistic Regression) 的原理。

线性回归 (Linear Regression) 是一种用于建立连续型目标变量与自变量之间线性关系的回归分析方法。它基于最小二乘法来拟合一个线性模型，通过求解模型参数来建立线性回归方程。

逻辑回归 (Logistic Regression) 是一种用于建立分类模型的回归分析方法。它虽然名字中带有“回归”，但实际上是一种分类算法，用于预测二分类或多分类的概率。逻辑回归使用逻辑函数 (sigmoid 函数) 来将线性模型的输出映射到 0 到 1 之间，表示概率值。

8、如何评估机器学习模型的性能？列举几个常见的评估指标。

评估机器学习模型的性能是判断模型好坏的重要指标。常见的评估指标包括：
分类问题：

准确率 (Accuracy)：分类正确的样本占总样本的比例。

精确率 (Precision)：真正例占所有预测为正例的样本的比例。

召回率 (Recall)：真正例占所有真正例的样本的比例。

F1 分数 (F1 Score)：精确率和召回率的调和平均值，综合考虑了分类器的准确性和召回率。

回归问题：

均方误差 (Mean Squared Error, MSE)：观测值与预测值之差的平方的均值。

均方根误差 (Root Mean Squared Error, RMSE)：MSE 的平方根。

平均绝对误差 (Mean Absolute Error, MAE)：观测值与预测值之差的绝对值的均值。

8、什么是过拟合 (Overfitting) 和欠拟合 (Underfitting)，如何解决这些问题？

过拟合 (Overfitting) 指的是模型在训练数据上表现很好，但在未见过的数据上表现较差。

欠拟合 (Underfitting) 则指在训练数据和测试数据上模型的表现都较差。*

解决过拟合问题的方法包括：

增加训练数据量。

减少模型复杂度，如减少特征数量或降低模型的层数。

使用正则化技术，如 L1 正则化和 L2 正则化，限制模型参数的大小。

使用交叉验证来选择合适的模型参数。

使用集成学习方法，如随机森林和梯度提升树，减少模型的方差。
解决欠拟合问题的方法包括：

增加模型复杂度，如增加特征数量或增加模型的层数。

使用更复杂的模型，如深度神经网络。

调整模型的超参数，如学习率、正则化参数等。

增加训练数据量。

在选择模型时，需要根据具体问题的特点和数据集的情况来选择合适的模型。常见的机器学习模型包括线性回归、逻辑回归、决策树、支持向量机、随机森林、梯度提升树等。

9、特征选择时要考虑哪些方面的内容。

在选择特征时，可以考虑以下几个方面：

目标变量的相关性：选择与目标变量相关性较高的特征。

特征之间的相关性：避免选择高度相关的特征，以减少冗余信息。

特征的可解释性：选择具有实际意义和可解释性的特征。

特征的稳定性：选择在不同数据集上表现稳定的特征。

特征选择的方法包括：

相关性分析：计算特征与目标变量之间的相关系数或互信息，选择相关性较高的特征。

方差分析：计算特征的方差，选择方差较大的特征。

嵌入式方法：在模型训练过程中自动选择特征，如 L1 正则化、决策树的特征重要性等。

递归特征消除：通过递归地训练模型并剔除最不重要的特征来选择特征。

10、解释一下数据抽样的方法和应用场景。

数据抽样是从一个大的数据集中选择一个子集作为代表性样本的过程。

常见的数据抽样方法包括简单随机抽样、分层抽样、系统抽样和群集抽样等。

简单随机抽样 (Simple Random Sampling)：从总体中随机选择样本，每个样本被选择的概率相等，确保样本的代表性。

分层抽样 (Stratified Sampling)：将总体划分为若干个相互独立的层，然后从每个层中进行简单随机抽样，以保证每个层的特征都得到充分的反映。

系统抽样 (Systematic Sampling)：从总体中选择一个起始点，然后每隔一定的间隔选择一个样本，例如选择第 k 个样本，直到达到预定的样本数量。

群集抽样 (Cluster Sampling)：将总体划分为若干个群集，然后随机选择若干群集作为样本，对所选群集中的所有个体进行观察。

数据抽样可应用于以下场景：

当数据集过大，无法一次处理时，可以抽取一个代表性样本来进行分析。

当数据采集成本较高时，可以通过抽样降低数据采集的成本。

当需要进行数据预处理、模型训练和验证时，可以使用抽样来加快计算速度。

在推荐系统中，通过用户抽样来评估推荐算法的效果。

11、如何处理大规模数据集？列举一些常见的大数据处理工具或技术。

处理大规模数据集时，可以采用以下常见的大数据处理工具或技术：

Apache Hadoop：提供分布式存储和计算的框架，适用于处理大规模结构化和非结构化数据。

Apache Spark：基于内存的分布式计算框架，提供高性能和可扩展性，适用于数据分析和机器学习。

Apache Kafka：用于高吞吐量的实时数据流处理和消息传输的分布式流平台。

HBase：分布式的、高可扩展性的 NoSQL 数据库，适用于实时读写大规模数据。

Amazon S3：亚马逊提供的对象存储服务，适用于大规模数据的持久性存储和访问。

12、解释一下数据仓库（Data Warehouse）和数据湖（Data Lake）的区别。

数据仓库（Data Warehouse）和数据湖（Data Lake）是两种不同的数据存储架构和管理模式：

数据仓库是一个集中的、经过处理和清洗的数据存储区域，用于支持业务决策和报表生成。数据仓库通常采用结构化的、预定义的模式来存储数据，并通过 ETL（抽取、转换和加载）过程将数据从源系统抽取到仓库中。

数据湖是一种存储原始、未经处理的海量数据的架构，它接受任何类型和格式的数据，并保留数据的原始形态。数据湖的数据通常以原始的、未加工的状态存储，不依赖于预定义的模式。数据湖可以支持更灵活和实时的数据分析和挖掘，适用于数据科学和探索性分析。

主要体现在以下几个方面

数据结构和模式：数据仓库通常采用预定义的模式和结构来组织数据，数据湖则可以接收任意格式和结构的数据，不要求预定义模式。

数据处理方式：数据仓库经过 ETL（抽取、转换、加载）和清洗等过程后，数据被处理为可分析的形式。数据湖保留原始的数据形态，可以在需要时进行处理和转换。

数据可用性和灵活性：数据仓库通常具有高度整合和预处理的特点，提供了高度可用和一致的数据。数据湖则着重于原始数据的积累和数据的灵活使用，能够快速适应不同的分析需求。

数据访问和权限控制：数据仓库通常有严格的访问和权限控制，通过用户名和密码等来限制

访问权限。数据湖较灵活，可以设置不同的访问层次和权限控制。

数据使用目的：数据仓库通常用于支持业务决策和报表生成，提供预定义的分析模型和指标。

数据湖提供了更广泛的数据探索和数据科学应用的可能性。

13、如何进行 A/B 测试？解释一下它的原理和流程。

A/B 测试是一种通过比较两个或多个版本的实验来评估策略、功能或设计的效果的方法。其原理和流程如下：

原理：A/B 测试基于假设，将用户分成多个群体，每个群体被随机分配到不同的实验条件（如 A 组和 B 组），然后比较不同组之间的表现差异，从而判断是否存在显著效果

流程

目标设定：明确要评估的指标、设定实验的目标。

选择变量：选择需要测试的变量，例如页面布局、按钮颜色等。

划分用户群体：将用户随机分为两个（或多个）群体，A 组和 B 组，使得每个群体具有相似的特征。

设计实验：针对 A 组和 B 组设计不同的实验条件，例如对 A 组采用原来的设计，对 B 组采用新的设计。

实施实验：将实验条件应用到相应的群体中，并记录结果数据。

分析结果：分析两个群体的结果数据，比较各组的指标（如转化率、点击率等）是否存在显著差异。

得出结论：根据结果数据，判断新设计是否对指标有积极影响，决定是否采用新设计。

14、什么是时间序列分析（Time Series Analysis）？列举一些常见的时间序列预测方法。

时间序列分析是一种统计方法，用于分析随时间变化的数据。它关注数据的时间顺序和相关模式，用于预测未来的数值。常见的时间序列预测方法包括：

移动平均法：根据过去一段时间窗口内的平均值进行预测。

指数平滑法：基于历史数据的平滑指数加权平均进行预测。

ARIMA 模型：自回归移动平均模型，用于建立时间序列数据的线性关系模型。

季节性分解法：将时间序列数据分解为趋势、季节性和随机成分，通过对这些成分建模进行预测。

LSTM：长短期记忆网络，一种适用于时间序列预测的深度学习模型。

15、解释一下主成分分析 (Principal Component Analysis, PCA) 的原理和应用。

主成分分析 (PCA) 是一种常用的降维技术，用于将高维数据转换为低维空间。

原理是通过线性变换将原始特征投影到新的特征空间，使得投影后的变量之间没有相关性，从而最大程度地保留原始数据的方差。主成分是新特征空间的线性组合，按照方差递减的顺序排序。

PCA 的应用包括：

数据压缩：通过 PCA 将高维数据转换为低维表示，可以减少存储和计算的成本。

数据可视化：通过 PCA 将高维数据可视化在二维或三维空间中，帮助直观理解数据的分布和结构。

特征选择：通过 PCA 确定最重要的主成分，对数据特征进行选择和排名。

噪声过滤：通过 PCA 过滤掉数据中的噪声和冗余信息，提高数据质量和模型性能。

特征提取：通过 PCA 提取出的主成分，可以用于训练机器学习模型或进行其他分析任务，减少输入特征的数量。

16、什么是 Z-score 及要注意的事项。

Z-score (Z 值) 是统计学中用于度量某个数值与其所在数据集平均值之间的偏离程度的标准化分数。它表示一个数值与平均值之间的差异，以标准差为单位进行度量。

计算 Z-score 的公式为： $Z = (X - \mu) / \sigma$

其中：

Z 是 Z-score 值；

X 是要计算 Z-score 的数值；

μ 是数据集的平均值 (均值)；

σ 是数据集的标准差。

Z-score 通过将原始数据转换为与平均值之间的差异，以标准差为度量单位来进行比较和分析。

Z-score 的值可以表示一个数值相对于整个数据分布的位置和偏离程度：

当 Z-score 为 0 时，表示该数值与平均值相等；

当 Z-score 为正值时，表示该数值大于平均值；

当 Z-score 为负值时，表示该数值小于平均值。

Z-score 常用于统计分析和异常值检测。通过计算 Z-score，可以对数据进行标准化，使得不同数据集之间可以进行比较和综合分析。在异常值检测中，可以使用 Z-score 来判断某个数值与平均值之间的偏离程度，从而标识是否存在异常值。

需要注意的是，Z-score 的计算基于数据的正态分布假设。如果数据不满足正态分布，Z-score 的应用可能会受到限制。

此外，Z-score 的值越大（绝对值越大），表示数值与平均值的偏离程度越大。一般来说，Z-score 大于 3 或小于 -3 可以被认为是显著偏离平均值的值。

当进行 Z-score 计算时，有几个要注意的方面：

数据分布的假设：Z-score 的计算基于数据满足正态分布的假设。如果数据不满足正态分布，Z-score 的应用可能会受到影响。在非正态分布情况下，可以考虑使用其他的标准化方法或非参数统计方法。

数据集大小：Z-score 对数据集的大小没有限制，可以用于小样本或大样本。然而，在较小的样本中，极端值（outliers）可能对 Z-score 的计算产生较大影响，因此需要谨慎处理。

数据的标准化：在计算 Z-score 之前，通常需要对数据进行标准化处理。标准化指将原始数据减去数据集的均值（ μ ），然后除以数据集的标准差（ σ ），以确保数据具有零均值和单位方差。

Z-score 的阈值：常见的 Z-score 阈值为 2 或 3。一般而言，绝对值大于 2 或 3 的 Z-score 被认为是显著偏离平均值的值。这可以作为异常值的参考，但具体的阈值选择要根据具体应用和领域知识进行评估和决策。

需要注意的是，Z-score 只提供了一个数值与平均值之间偏离程度的度量，不能单独用于判断数值的重要性或影响。在实际应用中，还需要结合其他分析方法和业务背景进行综合评估和解释

17、什么是高维稀疏数据

高维稀疏数据是指存在大量特征（高维）且其中大部分特征值为零（稀疏）的数据。在高维稀疏数据中，许多特征可能只在一小部分数据样本中出现，而其他特征则在较大部分样本中没有出现。

高维稀疏数据在许多领域中都很常见，如自然语言处理（文本数据）、推荐系统（用户行为数据）、生物信息学（基因表达数据）等。它们具有以下特点：

高维性：数据包含许多特征，通常远远超过样本数量。例如，文本数据中的每个单词可以被视为一个特征。

稀疏性：在高维数据中，大部分特征值为零。这是因为在真实世界的的数据中，特征之间通常不会同时存在。

高维稀疏数据在进行数据处理和分析时面临一些挑战：

维数灾难：随着维度的增加，数据变得更加稀疏，导致计算和存储成本的急剧上升。

数据稀疏性：稀疏数据使得建模和分析变得更加困难，因为许多传统方法在面对稀疏数据时可能会失效。

针对高维稀疏数据，一些常见的处理方法包括：

特征选择：通过选择最相关或最有代表性的特征，降低数据维度，减少噪声和冗余。

特征提取：利用降维技术（如主成分分析、因子分析等）将高维特征转换为低维表示，保留

最重要的信息。

稀疏编码：使用稀疏编码方法对数据进行压缩和表示，以减少存储和计算成本，同时保持原始数据的重要结构。

集成方法：结合多个模型或方法，综合利用多个特征选择或特征提取的结果，以提高预测性能。

需要根据具体的问题和数据特点选择适合的方法来处理高维稀疏数据，并结合领域知识和实际需求进行分析和建模

18、指标一致化中包括:极大型（指标的取值越大越好），极小型（指标的取值越小越好），居中型（数值越居中越好），区间型（最终取值落入某一个区间最佳）。居中型和区间型怎么处理。

居中型指标处理：

对于居中型指标，数值越居中越好，可以通过计算指标与其理想值之间的差异来进行处理。一种常见的方法是计算指标与理想值的绝对差异或相对差异，并将得到的差异值进行标准化。常用的标准化方法包括将差异值除以指标的标准差或范围，以确保不同指标的差异可比较。

对于居中型指标的处理，可能需要根据具体的业务需求和背景，权衡指标的重要性，并确定差异的阈值，以确定指标的一致化程度。

区间型指标处理：

区间型指标要求最终指标值落入某一个特定的区间才被认为是最佳的。

处理区间型指标的方法可以采用阈值设定和将指标值规范化的方式。

一种常见的方法是根据业务需求设定特定的区间阈值，将指标值映射到该区间内。可以考虑使用线性映射或逻辑映射等技术进行转换。

通过将指标值规范化到特定区间，可以使得区间型指标具有可比较性，并且有助于评估指标在给定区间内的表现。

19、当数据不满足正态分布时，如何处理使其满足正态分布

对数转换 (Log Transformation)：将数据取对数可以有效地压缩右偏（正偏）分布的数据，使其更接近正态分布。适用于数据严重右偏或含有指数增长的情况。

幂次转换 (Power Transformation)：通过对数据应用幂次函数（例如平方根、平方、反正切等）来改变数据的分布形态。常用的方法包括 Box-Cox 转换和 Yeo-Johnson 转换。

分位数转换 (Quantile Transformation)：通过对数据进行分位数映射，将原始数据转换为符合正态分布的数据。常用的方法包括 Rank-based 方法和分位数函数转换方法。

爱尔兰伯格-约翰逊转换 (Erlang-Johnson Transformation)：这是一种参数转换方法，通

过调整数据的位置和形状参数来使其更接近正态分布。

Box-Cox 变换：Box-Cox 变换是一种广泛使用的转换方法，它通过引入一个参数 λ 来调整数据的形状。适用于对数偏差或指数偏差的数据。

选择合适的转换方法需要根据数据的特点和分布偏差来确定。可以使用可视化工具（如直方图、Q-Q 图等）来评估转换的效果，并使用统计指标（如偏度、峰度等）来比较转换前后的数据分布。

需要指出的是，转换数据并不总能保证得到完全符合正态分布的结果，转换的结果可能仍存在一些偏差或不完美。因此，在进行转换时，应该结合具体的数据和分析需求进行权衡和调整。

20、当数据不满足正态时该如何处理

非参数统计方法：非参数统计方法不依赖于数据的分布假设，可以在不转换数据的情况下进行分析。例如，使用基于排名的方法，如 Wilcoxon 符号秩检验或 Mann-Whitney U 检验，来比较样本之间的差异。

采用鲁棒统计方法：鲁棒统计方法对异常值不敏感，在数据分布不满足正态性的情况下也能提供可靠的结果。例如，使用中位数和四分位数替代均值和标准差。

通过数据分箱 (Binning)：将连续的数据分成离散的区间，可以减少数据分布的偏差和异常值的影响，并使得数据更接近正态分布。可以使用等宽分箱或等频分箱的方法。

稳健回归分析：稳健回归方法能够降低异常值对回归结果的影响。例如，使用岭回归 (Ridge Regression) 或套索回归 (Lasso Regression) 等稳健回归模型。

集成学习方法：通过结合多个模型的预测结果 (ensemble methods)，可以减少对数据分布假设的依赖性，并得出更准确和稳健的预测结果。常见的集成学习方法包括随机森林 (Random Forest) 和梯度提升树 (Gradient Boosting Tree) 等。

21、SW 检验与 KS 检验的目的及使用场景

Shapiro-Wilk 检验和 Kolmogorov-Smirnov 检验是常用的统计检验方法，用于检验数据是否符合某个特定的理论分布，常用于正态性检验。

Shapiro-Wilk 检验的目的是检验数据是否来自正态分布。该检验基于数据与正态分布之间的差异进行推断，对小样本和大样本均适用。Shapiro-Wilk 检验的原假设是数据符合正态分布，备择假设是数据不符合正态分布。通过计算统计量和对应的 p 值，可以对原假设进行拒绝与否的判断。如果 p 值小于显著性水平（如 0.05），则可以拒绝原假设，说明数据不符合正态分布。

Kolmogorov-Smirnov 检验的目的是检验数据是否符合指定的累积分布函数 (CDF)，而不仅仅限于正态分布。该检验基于数据与理论分布之间的最大距离进行推断。与 Shapiro-Wilk 检验相比，K-S 检验更加灵活，可以适用于多种理论分布和样本大小。K-S 检验的原假设是数据符合理论分布，备择假设是数据不符合理论分布。通过计算统计量和对应的 p 值，可以对原假设进行拒绝与否的判断。如果 p 值小于显著性水平（如 0.05），则可以拒绝原假设，说明数据不符合指定的理论分布。

使用场景：

正态性检验：Shapiro-Wilk 检验和 K-S 检验常用于检验数据是否符合正态分布。这在许多统计方法中是一个重要的前提条件，例如 t 检验、方差分析等。如果数据不满足正态分布假设，可能需要寻找其他非参数统计方法。

分布拟合检验：K-S 检验可用于检验数据是否与某个指定的理论分布（如指数分布、对数正态分布等）拟合良好。在拟合概率分布模型时，这种检验可以帮助验证拟合的合理性。

数据预处理：正态性检验可以用于判断数据是否需要进行正态化转换。如果数据不符合正态分布，可能需要进行数据转换或选择适用于非正态数据的统计方法。

需要注意的是，正态性检验并不是决定数据是否可以进行统计分析的唯一因素。在实际应用中，还需综合考虑数据的特点、研究目的和具体分析方法来决定是否需要进行分布检验以及如何进一步的

22、中心极限定理与大数定理定义和关系

定义

中心极限定理 (Central Limit Theorem)：中心极限定理是指在一定条件下，当样本容量足够大时，样本均值的抽样分布会趋近于正态分布。换句话说，即使总体分布不服从正态分布，当样本容量足够大时，样本均值的分布将近似为正态分布。中心极限定理是统计学中最重要的理论之一，它为许多统计推断和假设检验提供了理论基础。

中心极限定理可以简洁地描述为：当样本量足够大时，随机变量的总和近似服从正态分布。

大数定理 (Law of Large Numbers)：大数定理是指当样本容量足够大时，样本均值会收敛于总体均值。具体而言，大数定理表明，当重复抽取大量独立同分布的样本时，这些样本的均值会趋近于总体均值。大数定理揭示了样本的平均值具有一致性和稳定性的特性。大数定理对于理解样本统计量的可靠性和稳定性具有重要意义。

大数定理可以简洁地描述为：当进行独立重复试验时，样本均值趋近于总体均值。

联系

中心极限定理是关于抽样分布的性质的定理。它指出，当样本容量足够大时，样本均值的抽样分布会近似于正态分布。中心极限定理是针对样本均值的分布性质给出了结论，并没有直接涉及样本均值与总体均值之间的关系。

大数定理是关于样本均值与总体均值之间的关系的定理。它指出，当样本容量足够大时，样本均值会收敛于总体均值。大数定理是对样本均值的稳定性和一致性给出了结论，它揭示了样本均值与总体均值之间的关系。

因此，可以说中心极限定理为大数定理提供了基础。中心极限定理表明了样本均值的抽样分布的性质，而大数定理揭示了样本均值与总体均值之间的关系。在实践中，中心极限定理经常被用于推断总体参数的分布，而大数定理常用于验证样本均值的稳定性和一致性。

综上所述，中心极限定理和大数定理是统计学中相互关联但又略有不同的概念，它们共同构成了统计学中基本的理论基础，并在统计推断和抽样理论中有广泛的应用。

23、第一类错误和第二类错误的定义及产生原因

第一类错误和第二类错误是统计学中的两种错误类型。

第一类错误，也称为假阳性 (Type I Error)，是在原假设为真的情况下，错误地拒绝了原假设。换句话说，第一类错误是当实际上没有效果或没有差异的情况下，错误地得出了有差异或有效果的结论。第一类错误的概率通常由显著性水平 (Significance Level) 来控制，通常约定为 α ，如 0.05 或 0.01。较小的显著性水平意味着更严格的判断标准，减少了犯第一类错误的概率，但也增加了犯第二类错误的概率。

第二类错误，也称为假阴性 (Type II Error)，是在原假设为假的情况下，错误地接受了原假设。换句话说，第二类错误是当实际上有差异或有效果的情况下，错误地得出了没有差异或没有效果的结论。第二类错误的概率通常由统计功效 (Statistical Power) 来描述，记作 β 。统计功效是正确地拒绝虚无假设的概率，也就是 1 减去第二类错误的概率。较高的统计功效意味着更容易检测到真实的效果。

在统计假设检验中，我们希望控制第一类错误的概率，即显著性水平，同时尽量降低第二类错误的概率。这需要在研究设计和样本大小上进行平衡，以最大程度地减少两种错误的可能性。

为了更好地理解第一类错误和第二类错误，让我们通过一个假设检验的示例来说明。

假设你是一家药物公司的研究员，你的目标是测试一种新药物是否对某种疾病有治疗效果。你设计了一个实验，将患有该疾病的患者随机分为两组：实验组和对照组。

原假设 (虚无假设)：新药物对疾病无治疗效果，即两组患者的治愈率没有差异。

备择假设：新药物对疾病具有治疗效果，即实验组的患者治愈率高于对照组。

现在我们来了解一下可能发生的错误情况：

第一类错误 (假阳性)：

发生场景：当实际上新药物对疾病无效时，但由于抽样变异性或其他原因，你的研究结果显示实验组的治愈率明显高于对照组。

结果：你错误地拒绝了原假设，即错误地得出了新药物对疾病有效的结论。这可能导致无效的药物得到误导性的推广和应用。

第二类错误 (假阴性)：

发生场景：当实际上新药物对疾病有效时，但由于样本容量较小或其他原因，你的研究结果显示实验组和对照组的治愈率没有显著差异。

结果：你错误地接受了原假设，即错误地得出了新药物对疾病无效的结论。这可能导致有用的药物未能及时得到认可和应用。

通过这个例子，我们可以看到第一类错误和第二类错误分别代表了在假设检验中犯错的两种情形。控制这两种错误的概率是统计推断中的重要考虑因素，以确保得出准确和可靠的结论。

第一、二类错误产生的原因：

第一类错误（假阳性）的产生原因：

设定显著性水平过高：如果在研究中将显著性水平设置得较高（例如， $\alpha = 0.10$ ），则更容易犯第一类错误，即错误地拒绝原假设。

样本容量小或抽样变异性大：小样本容量或抽样过程中的变异性增加了犯第一类错误的概率。

缺乏实验设计的控制：实验中可能存在的干扰因素或其他未控制的变量可能导致错误地得出有差异或有效果的结论。

第二类错误（假阴性）的产生原因：

样本容量小或抽样变异性大：小样本容量或抽样过程中的变异性增加了犯第二类错误的概率。样本容量过小可能导致无法检测到真实效果的存在。

设置显著性水平过低：较低的显著性水平（例如， $\alpha = 0.01$ ）要求更强的证据才能拒绝原假设，这可能增加了犯第二类错误的风险。

测量误差或方法限制：测量误差或方法的限制可能导致未能正确检测到实际上存在的差异或效果。

为了减少这两类错误的概率，研究人员需要仔细设计实验、设置适当的显著性水平和统计功效，并确保样本容量足够大以减少抽样变异性对结果的影响。此外，建议进行严格的数据分析和结果解释，以及参考相关领域的经验和先前的研究结果。

24、正则化方法有哪些

正则化方法是一种用于处理回归和分类等机器学习问题中的过拟合问题，并帮助解决多重共线性的技术。下面介绍几种常见的正则化方法：

岭回归（Ridge Regression）：岭回归在目标函数中引入 L2 范数的惩罚项，通过调整正则化参数来平衡拟合与正则化项之间的权衡。它可以减小回归系数的方差，对多重共线性问题有较好的处理效果。

套索回归（Lasso Regression）：套索回归在目标函数中引入 L1 范数的惩罚项，与岭回归不同，套索回归可以倾向于产生更稀疏的解（即某些系数为 0），因此可以用于特征选择和变量筛选。

弹性网（Elastic Net）：弹性网是岭回归和套索回归的结合，它在目标函数中同时引入 L1 范数和 L2 范数的惩罚项。弹性网可以在处理多重共线性问题的同时进行变量选择，减小冗余变量的影响。

主成分回归（PCR, Principal Component Regression）：PCR 是一种联合使用主成分分析和回归分析的方法。它通过主成分分析将自变量转换为一组不相关的主成分，然后将主成分作为新的自变量输入到回归模型中。

偏最小二乘回归 (PLSR, Partial Least Squares Regression): PLSR 是一种基于主成分分析的回归方法, 它考虑了因变量的信息, 将自变量和因变量之间的相关性最大化。PLSR 在处理多重共线性和高维数据方面具有一定优势。

这些正则化方法在不同情况下具有不同的优势和适用性。选择合适的正则化方法需要根据具体问题的性质和数据的特点来确定, 同时还可以通过交叉验证等方法来选择最优的正则化参数

25、正则化: L1 范数和 L2 范数

正则化范数是正则化方法中用来对目标函数引入惩罚项的一种方式。常见的正则化范数有 L1 范数和 L2 范数, 它们在正则化中起到控制模型复杂度和减小过拟合的作用。

L1 范数 (L1-norm): 也称为绝对值范数, 表示为 $\|x\|_1$ 。L1 范数将向量中各个元素绝对值之和作为惩罚项, 具体来说, 对于向量 $x=(x_1, x_2, \dots, x_n)$, L1 范数定义为 $\|x\|_1 = |x_1| + |x_2| + \dots + |x_n|$ 。

L1 范数在稀疏性特征选择和变量筛选中有很好的性质, 因为它倾向于产生稀疏的解, 即将某些系数推向 0, 从而实现特征选择和降维的效果。

L2 范数 (L2-norm): 也称为欧氏范数, 表示为 $\|x\|_2$ 。L2 范数将向量中各个元素的平方和的平方根作为惩罚项, 具体来说, 对于向量 $x=(x_1, x_2, \dots, x_n)$, L2 范数定义为 $\|x\|_2 = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$ 。

L2 范数在处理多重共线性和求解回归问题中常用, 它在一定程度上减小了异常值的影响, 对模型的平滑性有较好的控制能力。

在实际应用中, 岭回归 (L2 正则化) 和套索回归 (L1 正则化) 是常用的正则化方法, 它们分别使用了 L2 范数和 L1 范数对回归模型进行惩罚。另外, 弹性网回归 (Elastic Net) 同时结合了 L1 范数和 L2 范数的特点, 具有更灵活的调节能力。

选择合适的正则化范数需要考虑数据的特点、模型的目标以及领域的经验知识, 通过交叉验证等方法可以选择最佳的正则化参数。

26、Bagging 和 Boosting 的流程、异同、使用场景

Bagging 和 Boosting 是两种常见的集成学习方法, 它们都通过组合多个弱学习器来构建一个更强大的集成模型。它们的过程、异同和使用场景有一些区别。

Bagging 和 Boosting 是集成学习中常用的技术。Bagging 是通过构建多个独立的基学习器并取平均来降低模型的方差。Boosting 是通过逐步迭代训练模型, 并根据前一轮模型的错误来调整样本权重, 从而降低模型的偏差。

Bagging (袋装法) 的过程:

从原始数据集中随机有放回地抽取样本, 构建若干个大小相同的子数据集。

在每个子数据集上独立地训练弱学习器，例如决策树。

将多个弱学习器的预测结果进行平均（回归）或投票（分类）来得到集成模型的最终预测结果。

Boosting（提升法）的过程：

将弱学习器应用于完整的训练数据集，根据预测结果调整样本权重，使得先前预测错误的样本权重增加。

迭代地训练一系列弱学习器，每一轮都将更多关注先前预测错误的样本。

将多个弱学习器的预测结果通过加权平均（回归）或加权投票（分类）来得到集成模型的最终预测结果。权重通常与弱学习器的准确性相关。

异同点如下：

Bagging 方法基于并行思想，每个子模型都是独立建立的，且子模型权重相等。Boosting 方法基于串行思想，每个子模型都根据上一个子模型的表现进行权重调整。

Bagging 方法通过集成多个模型来减少方差，以提高模型的鲁棒性。Boosting 方法通过集成多个模型来减少偏差，以提高模型的预测能力。

Bagging 方法倾向于在弱学习器上使用高方差算法，如决策树。Boosting 方法倾向于在弱学习器上使用高偏差低方差算法，如 AdaBoost。

在训练集较小或维度较高的情况下，Bagging 方法通常表现更稳定，而 Boosting 方法通常适用于训练集较大的情况。

使用场景：

Bagging 在多数投票的分类问题和平均预测的回归问题中表现出色，对于降低过拟合风险并提高模型鲁棒性有效。适用于决策树、随机森林等模型。

Boosting 适用于复杂且高性能的分类和回归问题，能够提升模型的准确性。适用于 AdaBoost、Gradient Boosting、XGBoost 等模型。

需要根据具体问题的特点、数据集的规模和性质以及模型的需求来选择使用哪种方法。对于两种方法的集成学习，还可以通过调参和优化来进一步提升性能。

27、什么是偏差-方差权衡（Bias-Variance Tradeoff）？为什么要在建模过程中关注该问题？

偏差-方差权衡指的是模型的预测误差可以分解为偏差、方差和不可避免的误差之和。

较高的偏差表示模型过于简单，无法捕捉数据中的复杂模式；

较高的方差表示模型过于复杂，对数据中的噪声过于敏感。

在建模过程中，我们要关注偏差-方差权衡，以找到一个复杂度适当的模型，既能够良好地拟合数据，又能够泛化到新数据。

28、解释 p 值、显著性水平和置信水平的关系。

p 值是用于判断统计结果是否具有显著性的度量，它表示在零假设为真的情况下，观察到的数据或更极端情况出现的概率。

显著性水平指的是我们事先设定的拒绝零假设的临界值，常见的显著性水平有 0.05 和 0.01。

置信水平是对结果的置信程度，是我们接受备择假设的程度，常见的置信水平有 0.95 和 0.99。

29、详细解释 K-means 聚类方法的流程、优缺点及聚类中心的数量确认

K-means 聚类算法是一种常见的无监督机器学习算法，用于将数据集中的样本划分为 K 个不同的簇（clusters）。其原理如下：

初始化：随机选择 K 个聚类中心，可以从数据集中随机选择或通过其他初始化方法得到。

迭代聚类过程：

对于每个样本，计算其与各个聚类中心的距离（常用的距离度量方法是欧氏距离）。

将样本分配给距离最近的聚类中心，形成 K 个簇。

更新聚类中心：将每个簇中的样本的均值作为新的聚类中心。

迭代步骤 2，直到满足终止条件（例如达到最大迭代次数或聚类中心不再变化）：

对于每个样本，计算其与当前聚类中心的距离。

将样本分配给距离最近的聚类中心，形成 K 个簇。

更新聚类中心。

返回最终的聚类结果，每个样本被分配到一个簇中。

K-means 聚类算法的目标是最小化各样本与其所属簇中心的距离之和，即最小化簇内平方和总和（WCSS, Within-Cluster Sum of Squares）。这是一个迭代的过程，通过不断更新聚类中心来优化簇内的样本分布。

需要注意的是，K-means 聚类算法对初始聚类中心的选择非常敏感，不同的初始化可能导致不同的结果。为了获得更好的聚类效果，可以尝试多次运行算法并选择最好的结果，或使用其他初始化策略。

另外，K-means 聚类算法适用于连续型数值特征的数据集，并假设所有特征对聚类的贡献相等。当数据集中存在离群值或噪声、簇的形状不规则或大小不平衡时，K-means 算法可能表现不佳。在这些情况下，需要考虑使用其他聚类算法或对数据进行预处理。

优点：

简单且易于实现：K-means 算法的原理和步骤相对简单，易于理解和实施。

可扩展性：K-means 算法在处理大规模数据集时具有较好的可扩展性和高效性。

对处理高维数据有效：K-means 算法对于高维数据的聚类效果相对较好，并且在这种情况下计算速度较快。

可解释性：K-means 聚类结果相对容易解释，每个样本都被分配到一个簇中，簇的中心代表了该簇的特征。

缺点：

需要预先定义簇的数量：K-means 算法在执行之前需要指定簇的数量 K，不同的 K 值可能导致不同的聚类结果，且无法自动确定最优的 K 值。

对初始聚类中心选择敏感：K-means 算法对初始聚类中心的选择非常敏感，不同的初始中心可能导致不同的聚类结果。为了获得更好的效果，需要进行多次运行或尝试不同的初始化方法。

对离群值敏感：K-means 算法对于存在离群值或噪声的数据集比较敏感，它们可能会影响聚类结果的准确性。

仅适用于连续型数值特征：K-means 算法假设数据集中的特征对聚类贡献相等且为连续型数值特征，不适用于处理类别型特征或文本数据等其他类型的数据。

综上所述，K-means 聚类算法是一种简单且高效的聚类算法，适用于处理大规模数据集和高维数据。然而，它需要预先定义簇的数量，并对初始聚类中心选择敏感，对离群值敏感，并且仅适用于处理连续型数值特征的数据集。在实际应用中，需要根据具体问题和数据的特点来选择合适的聚类算法。

30、如何确认聚类中心的数量

确定聚类中心数量是 K-means 聚类算法中一个重要且具有挑战性的问题。以下介绍几种常用的方法来确定聚类中心的数量：

经验法则：

一般情况下，可以根据应用领域的经验知识或先验信息来估计合理的簇数量。例如，根据问题的背景知识或业务需求判断。

这种方法虽然简单，但可能由于主观判断而导致结果不准确。

肘部法则 (Elbow Method)：

通过绘制簇内平方和总和 (WCSS) 与聚类中心数量 K 的关系图，观察图像曲线的“肘部”位置，选择肘部对应的 K 值。

当 K 值增加时，WCSS 会逐渐减小，但随着 K 值增大，WCSS 的下降幅度会越来越小。选择肘部位置对应的 K 值，通常会在平滑曲线剧烈转折处。

这种方法依赖于可视化分析，需要人工观察并进行判断。

轮廓系数 (Silhouette Coefficient)：

轮廓系数综合考虑了簇内的紧密度和与相邻簇之间的分离度。计算每个样本的轮廓系数，并将所有样本的轮廓系数求平均，得到平均轮廓系数。

对于不同的 K 值，选择平均轮廓系数最大的 K 值作为簇的数量。

较高的平均轮廓系数表示聚类结果较好的紧凑性和分离度。

轮廓系数方法相对客观，但计算复杂度较高。

需要注意的是，上述方法仅为一些常用的估计方法，实际应用中可能需要结合问题的背景知识和实际情况进行综合考虑。同时，还可以尝试多次运行 K-means 算法并比较不同 K 值得到的聚类结果，选择效果最好的 K 值。

31、Excel 如何提取指定字符内容

分别提取货号和销售单编号里的字母和数字。

提取货号字母

=LEFT(C2, 3)

提取货号数字

=RIGHT(C2, 4)

提取单号字母

=LEFT(D2, FIND("-", D2) - 1)

提取单号数字

=MID(D2, FIND("-", D2) + 1, 100)

32、Excel 如何数据逆透视

将横向数据转为纵向数据，选择横向单元格区域，点击数据选项卡，点击获取与转换中的从表格，点击创建表。

在主页中单击将第一行用作标题。

按住 Ctrl 键选中不需要逆透视的列，在转化选项卡下点击逆透视其他列。

如框选的部分，数据完成逆透视，在主页选项卡下点击关闭并上载功能，将数据加载至 sheet 表中。

33、Excel 数据如何分组合并

数据分组后合并，选择单元格数据区域，点击数据选项卡，点击获取与转换中的从表格，点击创建表。

选择转换选项卡分组依据，分组类别为产品类别，柱为产品名称，操作为求和，点击确定。

将阴影选中的公式部分 List.Sum 替换为 Text.Combine。

如框选的部分，数据完成分组合并，在主页选项卡下点击关闭并上载功能，将数据加载至 sheet 表中。

34、SQL 的执行顺序

大多数编程语言代码都是按编码顺序执行的，但是在 SQL 语言中，第一个被执行的语句是 FROM 子句，每个步骤都会产生一个虚拟表，该虚拟表被用作下一个步骤的输入，如下的顺序即 SQL 的执行顺序。

```
(8)SELECT (9)DISTINCT (11)<Top Num> <select list>
(1)FROM [left_table]
(3)<join_type> JOIN <right_table>
(2)ON <join_condition>
(4)WHERE <where_condition>
(5)GROUP BY <group_by_list>
(6)WITH <CUBE | RollUP>
(7)HAVING <having_condition>
(10)ORDER BY <order_by_list>
```

35、计算用户的平均次日留存率

使用 date_add 计算一天后的日期，使用 distinct device_id,date 计算得出设备 ID 和答题日期，再计算第二天，再通过左连接，将构造的第二天和实际答题表对接，连接条件为设备 ID 相同，构造的第二天和真实的答题日期相同，因为是左连接，所以右侧没有符合条件的会是空值，最后就是 count 计算。

```
select count(t3.device_id)/count(t2.device_id) as avg_ret
from (select t1.*,date_add(t1.date,interval 1 day) as diertian
```

```

from (select distinct device_id,date from question_practice_detail ) as t1) as
t2
left join (select distinct device_id,date from question_practice_detail) as t3
on t2.device_id=t3.device_id and t2.date=t3.date;

```

36、批量合并同一文件夹不同工作簿数据

第一个方法，使用 OS 库遍历出文件夹中的各个工作簿名称，df 导入第一个工作簿，dfi 循环导入其他工作簿，最后使用 concat 函数进行两个列表合并。

```

import pandas as pd
import os
path=r'C:\Users\尚天强\Desktop\测试'
listdir=os.listdir(path)

df=pd.read_excel(path+'\\'+listdir[0])#导入第一个数据表
for filename in listdir[1:]:
    dfi=pd.read_excel(path+'\\'+filename) #导入除第一个数据表外其他数据表
    df=pd.concat([df,dfi]) #数据纵向合并
    df.to_excel(path+'\\'+ '数据合并.xlsx',index=False)

```

第二个方法，建立一个空的列表[]，df 跳过表头循环导入数据，将循环导入的数据使用 extend 函数合并值空的列表 dfs 中，最后用 concat 函数列表合并。

```

import pandas as pd
import os
dfs = []
read_path=r'C:\Users\尚天强\Desktop\测试数据'
save_path=r'C:\Users\尚天强\Desktop'
save_name='out_table.xlsx'

for fname in os.listdir(read_path):
    if fname.endswith(".xlsx") and fname !=save_name:
        df
        =
pd.read_excel(read_path+"\\"+fname, skiprows=1, header=None, sheet_name=None)
#names=['序列','日期','销量']
        dfs.extend(df.values())
#合并
result = pd.concat(dfs)

#导出数据

```

```
result.to_excel(save_path+"\\")+save_name, index=False, header=['id', 'number', 'sale'])
```

37、批量合并不同工作簿不同 sheet 表数据

该方法首先建一个空的表格，使用 openpyxl 库，循环导入不同工作簿，不同 sheet 表，不同行的数据，然后进行合并。

```
from openpyxl import Workbook, load_workbook
import os

def concat_data(file_path, save_path):
    files_name=os.listdir(file_path)
    #创建新表格
    new_wb=Workbook()
    new_ws=new_wb.active
    header=['销售日期', '员工工号', '销售员', '货号', '销售单编号', '销量', '销售额']
    new_ws.append(header)
    #向新的表格写入数据
    for file_name in files_name:
        wb=load_workbook(file_path+"\\")+file_name)
        for sheet in wb.sheetnames:
            ws=wb[sheet]
            for row in ws.iter_rows(min_row=2, values_only=True):
                new_ws.append(row)
    #数据保存
    new_wb.save(save_path+"\\")+“数据合并.xlsx”)

concat_data(r"C:\Users\尚天强\Desktop\2017 年销售明细", r"C:\Users\尚天强\Desktop")
```

3、Python 批量数据拆分

如果将汇总的数据表按照某个品牌或者企业进行批量拆分，首先使用 unique 函数将需要拆分的字段去重，然后使用 df.loc 函数循环筛选，最后数据导出。

```
import pandas as pd
df=pd.read_excel(r'C:\Users\尚天强\Desktop\数据批量拆分.xlsx')
city=df['城市'].unique().tolist()
for i in city:
    df1=df.loc[df['城市']==i]
```

```
df1.to_excel(r'C:\Users\尚天强\Desktop'+'\'+ i + '.xlsx', index=False)
```

38、Python 计算当前时间进度

计算当前的时间进度，定义一个字典，月份键对应着天数，使用 datetime 函数计算求得。

```
import datetime #时间进度
dic = {"1月": 31, "2月": 28, "3月": 31, "4月": 30, "5月": 31, "6月": 30, "7月": 31, "8月": 31, "9月": 30, "10月": 31, "11月": 30, "12月": 31}
for i in range(12):
    if datetime.datetime.now().month == i + 1:
        timing = round((datetime.datetime.now().day / dic["{}月".format(i + 1)]), 2)
        print('当前本月时间进度为: {:.0%}'.format(timing))
当前本月时间进度为: 35%
```

39、Python 计算数据环比

计算数据的环比，这里首先使用 numpy 构建一组随机数，然后使用 pct_change 函数计算环比，最后 apply 结合 lambda 函数自定义数据格式为保留两位小数的百分数格式。

```
import pandas as pd
import numpy as np
df=pd.DataFrame(data=np.random.randint(100, 500, (7, 1)),
                 index=pd.date_range('2021/12/01', periods=7),
                 columns=['销量'])
df['环比']=df['销量'].pct_change().apply(lambda x:format(x, '.2%'))
df
```

40、伯努利分布

已知某实验服从伯努利分布， $P(x=1)=0.6$ ，如果进行 2 次重复独立该实验，至少有一次实验结果为 0 的概率是多少？（）

A. 0.6 B. 0.4 C. 0.36 D. 0.84

答案解析：D

假设事件 A 为实验结果为 1，那么 $P(A) = 0.6$ ；

事件 A 的对立事件是实验结果为 0，那么 $P(\neg A) = 1 - P(A) = 1 - 0.6 = 0.4$ ；

因为实验是独立的，所以两次实验都是 0 的概率是 $P(\neg A) \times P(\neg A) = 0.4 \times 0.4$ ；

那么至少有一次实验结果为 0 的概率是 $1 - P(\neg A \times \neg A)$ ；

用数学公式，可以表示为： $P(\text{至少有一次实验结果为 } 0) = 1 - P(\text{两次都是 } 0 \text{ 的概率}) = 1 - 0.16 = 0.84$

41、概率论

在一个口袋中装有 5 个白球和 3 个黑球，这些球除颜色外完全相同，从中摸出 3 个球，至少摸到 2 个黑球的概率等于（ ）

A. $2/7$ B. $3/8$ C. $3/7$ D. $9/28$

答案解析：A

由题意知本题是一个古典概型。

42、EXCEL 数据分析 SUM 函数

若单元格 B2=30，B3=40，B4=52，则函数 SUM(B2，B4) 的值为（ ）

A. 122 B. 82 C. 92 D. 70

答案解析：B

SUM 函数用于计算指定单元格的总和。在这个例子中，单元格 B2 和 B4 的值分别为 30 和 52，所以 SUM(B2，B4) 的值为 $30+52=82$ 。因此，正确答案是 B。

43、若单元格 B2=30，B3=40，B4=52，则函数 SUM(B2:B4) 的值为（ ）

A. 122 B. 82 C. 92 D. 70

答案解析：A

SUM 函数用于计算指定单元格范围内的所有数值的总和。在这个例子中，单元格 B2、B3 和 B4 的值分别为 30、40 和 52，所以 SUM(B2:B4) 的值为 $30+40+52=122$ 。因此，正确答案是 A。

44、SQL 数据分析事务的特性

事务的执行结果必须使事务从一个状态转变到另一个一致性状态，是指事务的（）

A. 一致性 B. 原子性 C. 隔离性 D. 持续性

问题解析：A

已知事务有四个主要特性：原子性、一致性、隔离性和持久性。

- 原子性确保事务内的操作要么全部完成，要么全部不完成；
- 一致性确保在事务开始之前和事务结束以后，数据库的完整性没有被破坏；
- 隔离性确保并发执行的事务不会导致数据不一致；
- 持久性确保一旦事务提交，其结果应该是永久性的；

问题中描述“事务的执行结果必须使事务从一个状态转变到另一个一致性状态”，这实际上是指事务的“一致性”特性。

45、假设一个元组在子查询 1 中出现 3 次，在子查询 2 中出现 2 次，则该元组在“子查询 1 union 子查询 2”中出现几次？
()

A. 1 B. 2 C. 3 D. 5

问题解析：A

在 SQL 的 UNION 操作中，UNION 操作会去除重复的记录。因此，如果一个元组在子查询 1 中出现 3 次，在子查询 2 中出现 2 次，那么这个元组在“子查询 1 UNION 子查询 2”的结果中只会出现一次。

46、Python 公式计算

给定 a=8, b=3, 根据如下公式计算 $L1 = \text{round}(a/b, 2)$, 并保留两位小数 (round);

答案解析: 2.67

```
a = 8
b = 3
L1 = round(a/b, 2)
print(L1)
打印结果为: 2.67
```

面试题 2: Python 求和

从 1 加到 100, 总和是多少? 请用 Python 生成。

答案解析: 5050

可以使用 Python 的循环和变量来计算从 1 加到 100 的总和。以下是代码示例:

```
total = 0 # 初始化总和为 0
for i in range(1, 101): # 循环从 1 到 100
    total += i # 将每个数加到总和中
    print("从 1 加到 100 的总和是:", total)
从 1 加到 100 的总和是: 5050
```

47、数据分析思维付费转化率

如果做一个活动, 目标是 50w 流水, 假设活动页面的用户付费转化率是 0.4%, 假定单个用户可带来的平均收入是 20 元; 需要给页面带来 1W 流量 (UV) 才有可能达成目标? ()

A. 600 B. 625 C. 675 D. 425

答案解析: B

可以通过以下方式计算所需流量: $\text{流量} = (\text{目标流水} / \text{平均收入}) / \text{转化率}$

将目标流水设为 50w, 平均收入设为 20 元, 转化率设为 0.4%, 我们可以计算所需流量:

$\text{流量} = (500000 / 20) / 0.004 = 25000 / 0.004 = 625000$

所以, 需要给页面带来 625000 流量 (UV) 才有可能达成目标。

48、AARRR 模型

AARRR 模型分别对应用户生命周期中的每个阶段。 以下不属于某个阶段的是 ()

A. Activation B. Revenue C. Requirement D. Acquisition

答案解析: C

AARRR 模型分别对应用户生命周期中的每个阶段, 包括 Acquisition (获取)、Activation (激活)、Retention (留存)、Revenue (收入)、Refer (传播), 不包括 Requirement (需求)。

49、成为一名数据分析师需要具备哪些技能?

要成为一名数据分析师, 需要掌握丰富的报告软件包 (Business Objects), 编程语言 (XML, Javascript 或 ETL 框架), 数据库 (SQL, SQLite 等); 能够准确分析、组织、收集或传播数据; 掌握数据库设计, 数据模型, 数据挖掘等方面的技术知识以及分析大型数据集 (SAS, Excel, SPSS 等) 的统计软件包知识。

50、分析项目的各个步骤是什么?

分析项目的各个步骤包括:

- 问题定义
- 数据挖掘

数据准备

模型化

数据认证

实施跟踪

51、列出数据清理的最佳实践？

一些数据清理的最佳实践包括：

按不同的属性排序数据

对于大数据集，逐步清理并改进数据，直到获得良好的数据质量

对大型数据集，可以先将其分解为小数据集，使用更少的数据将增加迭代速度

要处理常见的清理任务，请创建一组实用程序函数/工具/脚本。它可能包括基于 CSV 文件或 SQL 数据库重映射值，或者正则表达式搜索和替换，消除所有不匹配正则表达式的值

如果在数据清理方面存在问题，请按照估计的频率进行安排并解决问题

分析每列的汇总统计数据(标准差，均值，缺失值的数量)

保持对每一个清理操作的跟踪，以便可以根据需要更改或删除操作

52、可用于数据分析的一些最佳工具清单有什么？

Tableau

RapidMiner

OpenRefine

KNIME

Google Search Operators

Solver

NodeXL

io

Wolfram Alpha' s

Google Fusion tables

53、数据挖掘和数据分析之间的区别是什么？

数据挖掘和数据分析之间的区别在于：

数据分析：针对个别属性的实例分析。提供有关属性的各种信息，如值范围，离散值及其频率，空值的发生，数据类型，长度等。

数据挖掘：重点关注聚类分析，异常记录检测，依赖关系，序列发现，多个属性之间的关系控制等。

54、用于处理分布式计算环境中应用程序大数据集的 Apache 框架有哪些？

Hadoop 和 MapReduce 是由 Apache 开发的用于处理分布式计算环境中应用程序大数据集的编程框架。

55、解释 KNN 插补方法是什么？

在 KNN 插补中，通过使用与其值缺失的属性最相似的属性值来推断缺失的属性值。通过使用距离函数，确定两个属性的相似度。

56、数据分析师使用的数据验证方法是什么？

通常，数据分析师用于数据验证的方法是数据筛选和数据验证。

57、解释应该如何处理可疑或缺失数据？

准备提供所有可疑数据信息的验证报告。它应该提供信息，如失败的验证标准以及发生的日期和时间

有经验的数据分析师应该检查可疑数据以确定其可接受性

应该找出无效数据并用验证码替换

对缺失数据进行处理，使用最佳分析策略，如删除，单一插补方法，基于模型的方法等。

58、如何避免过拟合？

过拟合表现在训练数据上的误差非常小，而在测试数据上误差反而增大。其原因一般是模型过于复杂，过分得去拟合数据的噪声和 outliers。常见的解决办法是正则化：增大数据集，正则化

59、解释异常值是什么？

异常值是分析师使用的一个术语，指的是一个远远超出样本总体模式的值。有两种类型的异常值：

Univariate

Multivariate

60、解释分层聚类算法是什么？

分层聚类算法结合并划分现有的组，创建分层结构并展示组划分或合并的顺序。

61、解释 K 均值算法是什么？

K 均值是一种著名的分区方法。对象被分类为属于 K 个组中的一个，k 是先验选择的。

在 K 均值算法中：

簇是球形的：簇中的数据点以该簇为中心

簇的方差/扩展是相似的：每个数据点属于最接近的簇

62、数据分析师所需掌握的关键技能是什么？

数据科学家必须具备以下技能：

数据库知识

数据库管理

数据混合

数据查询

数据操作

预测分析

基本描述性统计

预测建模

高级分析

大数据知识

大数据分析

非结构化数据分析

机器学习

演示技巧

数据可视化

报告设计

63、解释协同过滤是什么？

协同过滤是一种基于用户行为数据创建推荐系统的简单算法。协同过滤最重要的组件是用户对项目的兴趣。

协同过滤一个很好的例子就是购物网站上出现的类似“为您推荐”的模块，该模块通常会获取用户的浏览记录信息，以弹出用户可能喜欢或需要的商品。

64、大数据中通常会使用到哪些工具？

大数据中使用的工具包括：

Hadoop

Hive

Pig

Flume

Mahout

Sqoop

65、解释什么是 KPI，实验设计和 80/20 规则？

关键绩效指标(KPI)：它代表关键绩效指标(Key Performance Indicator)，它是关于业务流程的报告或图表

实验设计：这是用于分解数据，采样和建立数据以进行统计分析的初始过程

80/20 规则：这意味着你收入的 80%来自客户的 20%

66、解释 Map Reduce 是什么？

Map-Reduce 是一个处理大型数据集的框架，可以将它们分解成子集，在不同的服务器上处理每个子集，然后混合每个子集上获得的结果。

67、解释聚类是什么?聚类算法的属性？

聚类是一种应用于数据的分类方法。聚类算法将数据集划分为自然组或集群。

聚类算法的属性是：

Hierarchical or flat

Iterative

Hard and soft

Disjunctive

68、对数据分析师有用的统计方法是什么？

对数据科学家有用的统计方法是

贝叶斯方法

马尔科夫过程

空间和集群进程

统计数据，百分位数，异常值检测

计算技巧等

简单的算法

数学优化

69、时间序列分析是什么？

时间序列分析可以在频域和时域两个域中完成。在时间序列分析中，可以通过指数平滑，对数线性回归等各种方法分析数据，来预测特定过程输出。

70、解释空间自相关分析是什么？

空间自相关分析是地理空间分析的常用形式。它由一系列为不同空间关系计算的估计自相关系数组成。当原始数据表示为距离而不是单个点的值时，它可以用于构建基于距离的数据相关图。

71、散列表是什么?散列表冲突是什么?如何避免?

在计算中，哈希表(散列表)是键值对的映射，这是一个用于实现关联数组的数据结构。它使用散列函数来计算一个时隙阵列的索引，从中可以获取所需的值。

当两个不同的键散列到相同的值时，发生散列表冲突。两个数据不能存储在阵列的同一个插槽中。

为了避免散列表碰撞，有很多技巧，这里列出两个：

分离链接：它使用数据结构来存储散列到同一个插槽的多个项目。

再探测：在找到查找位置的 $index$ 的 $index-1$ ， $index+1$ 位置查找， $index-2$ ， $index+2$ 查找，依次类推。这种方法称为线性再探测。

72、解释 imputation 是什么?列出不同类型的插补技术?哪种插补方法更有利?

在插补过程中，我们用替代值替换丢失的数据。插补技术涉及的类型有：

单一插补

热点插补：从随机选择的类似记录中推断缺失值

冷却板插补：与热点插补相同，但更先进，从其他数据集中选择供体

平均估算：在所有其他情况下，用该变量的平均值代替缺失值

回归插补：用基于其他变量的变量预测值替换缺失值

随机回归：与回归插补一样，但它将平均回归方差加入到回归估计中

多重插补：与单个插补不同，多重插补会多次估计值

虽然单一插补法被广泛使用，但并不能反映随机丢失数据所造成的不确定性。因此，在数据丢失的情况下，多重插补更有利。

73、解释 N-gram 是什么？

N-gram 是来自给定序列文本或语音的 n 个项目的连续序列。这是一种以 $(n-1)$ 形式预测下一个项目的概率语言模型。

74、T 检验和 ANOVA 都是用来查看样本之间均值是否相等，但是两者又有什么区别呢？

卡方检验是用来看分类变量之间有没有相关性。

其实核心的区别在于：数据类型不一样。如果是定类和定类，此时应该使用卡方分析；如果是定类和定量，此时应该使用方差或者 T 检验。

方差和 T 检验的区别在于，对于 T 检验的 X 来讲，其只能为 2 个类别比如男和女。如果 X 为 3 个类别比如本科以下，本科，本科以上；此时只能使用方差分析。

方差分析

从理论上讲，方差分析有两个前提条件，一是因变量 Y 需要满足正态性要求，二是满足方差齐检验。

方差不齐时可使用‘非参数检验’，同时还可使用 welch 方差，或者 Brown-Forsythe 方差，非参数检验是避开方差齐问题

1.2 说一个简单的场景，问用什么统计检验方法可以比较两个样本的均值是不是不同
t 检验，两样本的 t 检验，可以检验两样本所代表的总体均数是否相等。

1.3 有什么统计检验方法

t 检验，方差分析和卡方检验

1.4 假设检验流程描述

建立假设统计量，给出拒绝域的形式

确定检验水准

计算 p 值

得出结论

1.5 样本量 n 如何确定（需要啥数据）

确定样本量：

知道被测试的参数分布吗？知道，均值是一个还是两个？一个，知道方差，正态分布；不知道，t 分布。均值是两个，知道方差吗？知道，独立，正态分布，不独立，也是正态分布；不知道，独立，很难找到，不独立，t 分布。

不知道被测试的分布，如果参数的先验可以得到或者可以估计，就估计参数，均值之类的。

75、男生点击率增加，女生点击率增加，总体为何减少？

因为男女的点击率可能有较大差异，同时低点击率群体的占比增大。

如原来男性 20 人，点击 1 人；女性 100 人，点击 99 人，总点击率 $100/120$ 。

现在男性 100 人，点击 6 人；女性 20 人，点击 20 人，总点击率 $26/120$ 。

即那个段子“A 系中智商最低的人去读 B，同时提高了 A 系和 B 系的平均智商。”

1.7 参数估计与假设检验

用样本统计量去估计总体的参数。

参数估计和假设检验是统计推断的两个组成部分，它们都是利用样本对总体进行某种推断，但推断的角度不同。

参数估计讨论的是用样本估计总体参数的方法，总体参数 μ 在估计前是未知的。

而在假设检验中，则是先对 μ 的值提出一个假设，然后利用样本信息去检验这个假设是否成立。

1.8 置信度、置信区间

置信区间是我们所计算出的变量存在的范围，置信度就是我们对于这个数值存在于我们计算出的这个范围的可信程度。

举例来讲，有 95% 的把握，真正的数值在我们所计算的范围内。

在这里，95% 是置信水平，而计算出的范围，就是置信区间。

如果置信度为 95%，则抽取 100 个样本来估计总体的均值，由 100 个样本所构造的 100 个区间中，约有 95 个区间包含总体均值。

1.9 协方差与相关系数的区别和联系

协方差：协方差表示的是两个变量的总体的误差，这与只表示一个变量误差的方差不同。

如果两个变量的变化趋势一致，也就是说如果其中一个大于自身的期望值，另外一个也大于自身的期望值，那么两个变量之间的协方差就是正值。如果两个变量的变化趋势相反，即其中一个大于自身的期望值，另外一个却小于自身的期望值，那么两个变量之间的协方差就是负值。

相关系数：研究变量之间线性相关程度的量，取值范围是 $[-1,1]$ 。相关系数也可以看成协方差：一种剔除了两个变量量纲影响、标准化后的特殊协方差。

76、 中心极限定理

定理： 假设从均值为 μ , 方差为 σ^2 的有限的任意一个总体中抽取样本量为 n 的样本，当 n 充分大时，样本的均值的抽样分布就会服从均值为 μ , 方差为 $\frac{\sigma^2}{n}$ 的正态分布。

在分析领域，我们每天都会遇到各种各样的数据，而源数据的分布并不总是被我们所知道的，但是，因为我们了解中心极限定理，所以我们甚至不需要关心源数据的分布，因为我们总是可以得到正态分布。

中心极限定理的作用：用样本数据估计总体参数（区间估计）。

77、均值正态分布的实际含义：

我们可以用均值的正态分布来分配置信区间。

我们可以进行 T 检验（即两个样本均值之间是否存在差异）

我们可以进行方差分析（即 3 个或更多样本的均值之间是否存在差异）

78、p 值的含义

基本原理只有 3 个：1、一个命题只能证伪，不能证明为真 2、在一次观测中，小概率事件不可能发生 3、在一次观测中，如果小概率事件发生了，那就是假设命题为假

证明逻辑就是：我要证明命题为真 $\rightarrow$ 证明该命题的否命题为假 $\rightarrow$ 在否命题的假设下，观察到小概率事件发生了 $\rightarrow$ 否命题被推翻 $\rightarrow$ 原命题为真 $\rightarrow$ 搞定。

结合这个例子来看：证明 A 是合格的投手 $\rightarrow$ 证明“A 不是合格投手”的命题为假 $\rightarrow$ 观察到一个事件（比如 A 连续 10 次投中 10 环），而这个事件在“A 不是合格投手”的假设下，概率为 p ，小于 0.05 $\rightarrow$ 小概率事件发生，否命题被推翻。

可以看到 p 越小 $\rightarrow$ 这个事件越是小概率事件 $\rightarrow$ 否命题越可能被推翻 $\rightarrow$ 原命题越可信

79、大数定律（Law of Large Number）

大数定律：每次从总体中随机抽取 1 个样本，这样抽取很多次后，样本的均值会趋近于总体的期望。也可以理解为：从总体中抽取容量为 n 的样本，样本容量 n 越大，样本的均值越趋近于总体的期望。当样本容量极大时，样本均值

80、 PCA 为什么要中心化？ PCA 的主成分是什么？

因为要算协方差。

单纯的线性变换只是产生了倍数缩放，无法消除量纲对协方差的影响，而协方差是为了让投影后方差最大。

在统计学中，主成分分析（PCA）是一种简化数据集的技术。它是一个线性变换。这个变换把数据变换到一个新的坐标系统中，使得任何数据投影的第一大方差在第一个坐标(称为第一主成分)上，第二大方差在第二个坐标(第二主成分)上，依次类推。

主成分分析经常用减少数据集的维数，同时保持数据集的对方差贡献最大的特征。这是通过保留低阶主成分，忽略高阶主成分做到的。这样低阶成分往往能够保留住数据的最重要方面。但是，这也不是一定的，要视具体应用而定。

主成分分析的原理是设法将原来变量重新组合成一组新的相互无关的几个综合变量,同时根据实际需要从中可以取出几个较少的综合变量尽可能多地反映原来变量的信息的统计方法叫做主成分分析或称主分量分析，也是数学上处理降维的一种方法。主成分分析是设法将原来众多具有一定相关性（比如 P 个指标），重新组合成一组新的互相无关的综合指标来代替原来的指标。

1.14 特征工程

81、 假设检验结果判定的 3 种方式

计算统计量 z,t,卡方，当检验统计量的值落入拒绝域内时，拒绝原假设

计算 p 值， $p < \alpha$ 时拒绝原假设

计算 $1-\alpha$ 的置信区间，均值落入置信区间，接受原假设。

1.16 方差齐性检验

对控制变量不同水平下各观测变量总体方差是否相等进行检验。

82、 t 检验

t 检验通常分为三种，分别是单样本 t 检验、双样本 t 检验和配对样本 t 检验。

无论哪种 t 检验，都有以下的基本前提条件：

样本数据符合正态分布

各个样本之间是独立的

步骤：

提出原假设和备择假设

构造 t 统计量

计算 t 统计量

对于得到的 p 值进行分析，p 大于 0.05 则接受原假设，反之接受备择假设。

单样本 t 检验：对某个样本的均值进行检验，比较是否和总体的均值(自己定) 是否存在差异。使用 `ttest_1samp` 函数实现，第一个参数为样本数据，第二个参数为总体均值。

双样本 t 检验：是针对两组不相关样本（各样本量可以相等也可以不相等），检验它们在均值之间的差异。对于该检验方法而言，我们首先要确定两个总体的方差是否相等，如果不等，先利用 `levne` 检验，检验两总体是否具有方差齐性，再使用 `stats.ttest_ind(A,B,equal_var=True)` 进行独立样本 t 检验

配对 t 检验：是针对同一组样本在不同场景下均值之间的差异。检验的是两配对样本差值的均值是否等于 0，如果等于 0，则认为配对样本之间的均值没有差异，否则存在差异。选择实现配对样本 t 检验的 `stats.ttest_rel(A0,A1)` 函数（两组样本作为输入）

83、查准率和查全率

查准率（Precision ratio，简称为 P），是指检出的相关文献数占检出文献总数的百分比。查准率反映检索准确性，其补数就是误检率。查全率（Recall ratio，简称为 R），是指检出的相关文献数占系统中相关文献总数的百分比。查全率反映检索全面性，其补数就是漏检率。

查全率 = (检索出的相关信息量/系统中的相关信息总量) * 100%。查准率 = (检索出的相关信息量/检索出的信息总量) * 100%。利用这两个量化指标，也可以对信息检索系统的性能水平进行评价。要评价信息检索系统的性能水平，就必须在一个检索系统中进行多次检索。每进行一次检索，都计算其查准率和查全率，并以此作为坐标值，在平面坐标图上标示出来。通过大量的检索，就可以得到检索系统的性能曲线。

实验证明，在查全率和查准率之间存在着相反的相互依赖关系—如果提高输出的查全率，就会降低其查准率，反之亦然。对查全率和查准率之间的关系理解，如果提高了查全率，也就说明中间的阴影部分变大了同时系统中的相关文献总量应该不变。但准确率提高跟检出的总数相关，实际是要想查到更多相关的，那么检出的不相干也更多，即图中浅蓝色部分也变大，导致准确率变低。

84、相关系数的计算方法

斯皮尔曼等级相关系数（spearman 相关系数）

$Cov(X,Y)$ 为 X 与 Y 的协方差， $Var[X]$ 为 X 的方差， $Var[Y]$ 为 Y 的方差

2. 马修斯相关系数 (Matthews correlation coefficient)

马修斯相关系数是问题及其对偶的回归系数的几何平均数。

85、切比雪夫定理

切比雪夫定理 (Chebyshev's theorem): 适用于任何数据集, 而不论数据的分布情况如何。

所有数据中, 至少有 $3/4$ (或 75%) 的数据位于平均数 2 个标准差范围内。

所有数据中, 至少有 $8/9$ (或 88.9%) 的数据位于平均数 3 个标准差范围内。

所有数据中, 至少有 $24/25$ (或 96%) 的数据位于平均数 5 个标准差范围内

86、经验法则

经验法则 (Empirical Rule): 需要数据符合正态分布。

大约 68% 的数据值与平均数的距离在 1 个标准差之内;

大约 95% 的数据值与平均数的距离在 2 个标准差之内;

几乎所有的数据值与平均数的距离在 3 个标准差之内;

87、极大似然估计

利用已知的样本结果, 反推最有可能 (最大概率) 导致这样结果的参数值。

1.23 常见分布的期望与方差

1.24 正态总体参数的区间估计

88、介绍一下 A/B 测试

AB 测试, 是验证假设的好方法。

大家在实验中常用到实验思维, 根据实验思维, 我们要更好的进行归因实验, 通常要满足以下条件:

- * 对照：有其他对照组作为对比，就能真正看出来效果。而且不同组间的效果差异要足够明显，才能验证我们的判断
- * 随机：为了排除实验条件以外的干扰因素，我们需要确保两个组的用户是随机选取的，这是为了排除用户差异对实验结果的影响
- * 大样本：这里的样本量是指数据量，包括用户、行为和时间跨度，样本量越大，越容易排除个体差异的影响，也更容易验证统计上的显著性

应用时要注意平台，不同平台的环境、用户、产品特点不同，要结合实际。

****实践：****

在企业里，一般做 AB 测试有 3 块工作要做。分别是流量分配、实验设计和数据统计。

****流量分配****

- 1
- 2
- 3
- 4
- 5
- 6

产品快速迭代时，会有很多 AB 测试需要同时做，而产品的流量又是有限的，因此我们需要进行充分的流量切分。分流的逻辑如下图所示：

域：域是指整体流量的分区，域之间是互斥的。比如按照用户 ID 尾号奇偶性，将整体流量分为了 1、2 两个域，这个时候域 1+域 2=100%的流量，不同域之间的流量不会重叠。划分域的目的，是为了进行完全纯净的分区，更好的进行互不干扰的实验测试。

层：层是指某个域内全部流量的一个观测角度。比如对同一个域内流量，你可以按照用户 ID 尾号进行细分，也可以按照用户 ID 首号码进行细分。不同的细分方法，对应的也就是不同的层。不难理解，层与层之间的关系是正交的，即彼此互不影响，相互独立。

桶：在每个层中，我们使用独立的 Hash 函数对用户进行取模，将用户均匀的分配至 N 个实验桶中。桶与桶之间是互斥的。如下图所示，在 A 层中有 A1/A2/A3/A4 这 4 个桶，他们彼此互斥，互不重叠，彼此加和后等于层内的全部流量。我们可以用 A1/A2 进行 X 实验，同时用 A3/A4 进行 Y 实验

89、实验设计：

1.单因素实验设计

所谓单因素实验设计，是指实验中只有一个影响因素变量，其他的内容都保持不变的实验方法。举个例子，两个实验组，一组用广告图 A，一组用广告图 B，这两个组进行实验对比，最后发现 A 组比 B 组效果好，那么我们就可以认为这是 A 广告图的作用。

2.多因素实验设计

多因素实验设计，是指实验中有多个影响因素变量。比如你想同时测试广告图（AB）和广告弹出方式（AB）对转化率的影响，这里面有两个变量，对应的有 4 种组合条件：

广告 A, 弹出方式 A

广告 A, 弹出方式 B

广告 B, 弹出方式 A

广告 B, 弹出方式 B

多因素实验设计的好处在于,除了可以检测同一个变量、不同实验条件之间的差异之外,还能对变量之间的交互效果进行检验。用上个例子做说明,如果在单因素 AB 实验里,我们发现广告 A 比广告 B 的效果好,弹出方式 A 比弹出方式 B 的效果好,但是广告 A+弹出方式 A 的组合情况却不是最好的,因为他们之间的组合,产生了化学作用。这种情况下,就必须使用多因素实验设计来做。

数据分析:

1.考虑空跑期差异

一个不用统计的简单分析方法,是考虑空跑期差异。所谓空跑期,就是指什么策略也不做,纯看两个组本身的固有差异,作为判断的基础。而后用实验期的差异减去空跑期差异,就得到了实验的真实收益。具体来说分这么几个步骤:

看两个组在空跑期的数据差异(百分比),判断组间差异基础

看两个组在实验期的数据差异(百分比),判断实验差异

用实验期的差异减去空跑期的差异,得到实验真实收益

2.统计检验:

不考虑空跑期差异,而是直接看实验期里两个组的明细数据,输入到统计软件中进行统计分析,看是否显著($P < 0.05$)。如果显著,说明两组有明显差异

常用的统计分析有两种:

独立样本 T 检验

方差分析

5%就是在统计学里称作 α ,它代表着我们这个试验结果的置信水平。与这个置信水平相对应的就是置信区间的置信度,由 $1 - \alpha$ 得出,所以你在这里看到如果 α 是 0.05,那置信度就是 0.95,也就是说,如果我们容许自己出错的几率是 5%,那我们将得到一个有 95% 的可能性包含真实的总体均值区间范围,如果你把这个 α 调整成 0.07,那你的置信区间的置信度将变成 93%。

由于 α 是我们自己设置的,那么当然需要通过数据去验证一下,这个通过计算出来的值就是 p-value, p 的定义就是,如果两个版本无差异的前提下,我们得到这个试验数据的概率。

$p \leq \alpha$ 则意味着我们的测试得到了统计显著的结果,因为只有我们得到的这个 p 的概率越小,我就可以越有信心的地根据小概率事件不会发生的判断依据,从而推翻原假设,接受备择假设。

计算比例,用 z 检验。

90、每周要提交周 report,但建模可能不会每周都有结果,在没有成果的周,你的 report 要怎么写

分析没有结果的原因。

91、数据挖掘项目怎么做的用户分类

用户划分这样的分类问题的知识和理解

92、假设今天比昨天完单量下降 10%，找到原因

首先采用“两层模型”分析：对用户进行细分，包括新老、渠道、活动、画像等多个维度，然后分别计算每个维度下不同用户的次日留存率。通过这种方法定位到导致留存率下降的用户群体是谁。

对于目标群体次日留存下降问题，具体情况具体分析。具体分析可以采用“内部-外部”因素考虑。

a：内部因素分为获客（渠道质量低、活动获取非目标用户）、满足需求（新功能改动引发某类用户不满）、提活手段（签到等提活手段没达成目标、产品自然使用周期低导致上次获得的大量用户短期内不需要再使用等）；

b：外部因素采用 PEST 分析（宏观经济环境分析），政治（政策影响）、经济（短期内主要是竞争环境，如对竞争对手的活动）、社会（舆论压力、用户生活方式变化、消费心理变化、价值观变化等偏好变化）、技术（创新解决方案的出现、分销渠道变化等）。

2.6 询问打车 app 用的多还是外卖 app 用的多，如何预测

93、女装销量下降了分析原因（拆解+定位原因）

销量=用户*付费

划分维度，定位到真正发生变化的位置，

SWOT：天气变化，竞品优惠，外部渠道变化，用户偏好变化；自身产品，近期是否举办了活动。

新老用户，老用户消费了，新用户没有吸引到。

用户、产品、渠道

首先要定位到现象真正发生的位置，到底是谁的销售额变低了？这里划分的维度有： a. 用户（画像、来源地区、新老、渠道等） b. 产品或栏目 c. 访问时段

定位到发生位置后，进行问题拆解，关注目标群体中哪个指标下降导致网站销售额下降： a. 销售额=进站流量 x 下单率 x 客单价 b. 进站流量 = $\sum$ 各来源流量 x 转化率 c. 下单率 = 页面访问量 x 转化率 d. 客单价 = 商品数量 x 商品价格

确定问题源头后，对问题原因进行分析，如采用内外部框架： a. 内部：网站改版、产品更新、广告投放 b. 外部：用户偏好变化、媒体新闻、经济环境、竞品行为等。

94、 不用任何公开参考资料，估算今年新生儿出生数量。

采用两层模型（人群画像 x 人群转化）：新生儿出生数 = $\sum$ 各年龄层育龄女性数量 * 各年龄层生育比率

从数字到数字：如果有前几年新生儿出生数量数据，建立时间序列模型（需要考虑到二胎放开的突变事件）进行预测，找先兆指标，如婴儿类用品的新增活跃用户数量 X 表示新生儿家庭用户。Xn/新生儿 n 为该年新生儿家庭用户的转化率，如 X2007/新生儿 2007 为 2007 年新生儿家庭用户的转化率。该转化率会随平台发展而发展，可以根据往年数量推出今年的大致转化率，并根据今年新增新生儿家庭用户数量推出今年估计的新生儿数量。

2.10 类比到头条的收益，头条放多少广告可以获得最大收益，不需要真的计算，只要有个思路就行。

收益 = 出价 x 流量 x 点击率 x 有效转化率，放广告的数量会提高流量，但会降低匹配程度，因此降低点击率。最大收益是找到这个乘积的最大值，是一个有约束条件的最优化问题。

提高单位溢价的方法：

- (1) 品牌打造获得长期溢价，但缺陷是需要大量前期营销投入；
- (2) 价格歧视，根据价格敏感度对不同用户采用不同定价。

销售量 = 流量 x 转化率，上述提高单位溢价的方法可能对流量产生影响，也可能对转化率产生影响。

收益 = 单价 x 流量 x 转化率，短期内能规模化采用的应该是进行价格歧视，如不同时间、不同商圈的价格不同，采取高定价，然后对价格敏感的用户提供优惠券等。

95、 PP 激活量的来源渠道很多，怎样对来源渠道变化大的进行预警？

如果渠道使用时间较长，认为渠道的 app 激活量满足一个分布，比较可能是正态分布。求平均值和标准差，对于今日数值与均值差大于 3/2/1 个标准差的渠道进行预警。

对于短期的新渠道，直接与均值进行对比。

96、 某业务部门在上周结束了为期一周的大促，作为业务对口分析师，需要你对活动进行一次评估，你会从哪几方面进行分析？

- (1) 确定大促的目的：拉新？促活？清库存？

(2) 根据目的确定核心指标。

(3) 效果评估：

a. 自身比较：活动前与活动中比较

b. 与预定目标比

c. 与同期其它活动比

d. 与往期同类活动比

(4) 持续监控：

a. 检查活动后情况，避免透支消费情况发生

b. 如果是拉新等活动，根据后续数据检验这批新客的质量

97、现在有一个游戏测试的环节，游戏测试结束后需要根据数据提交一份 PPT，这个 PPT 你会如何安排？包括什么内容？

这里可以套 AARRR 模型：

获取：我们的用户是谁？用户规模多大？

激活：游戏是否吸引玩家？哪个渠道获取的用户有质量（如次日留存高、首日停留时间长等）？

留存：用户能否持续留存？哪些用户可以留存？

转化：用户的游戏行为如何？能否进行转化？能否持续转化？

自传播：用户是否会向他人推荐该游戏？哪种方式能有效鼓励用户推荐该游戏？传播 k 因子是否大于 1？

98、怎么做恶意刷单检测？

分类问题用机器学习方法建模解决，我想到的特征有：

商家特征：商家历史销量、信用、产品类别、发货快递公司

用户行为特征：用户信用、下单量、转化率、下单路径、浏览店铺行为、支付账号

环境特征（主要是避免机器刷单）：地区、ip、手机型号等

异常检测：ip 地址经常变动、经常清空 cookie 信息、账号近期交易成功率上升等

评论文本检测：刷单的评论文本可能套路较为一致，计算与已标注评论文本的相似度作为

特征

图片相似度检测：同理，刷单可能重复利用图片进行评论

99、app 最重要的 3-5 个指标

留存率

保留率是用户在初始安装后，在特定时间范围内，返回到 APP 的用户所占的百分比，保留率也是衡量应用程序“粘性”的指标之一。您的应用程序对用户的价值越高，您的应用程序使用的频率就越高(被删除的可能性就越小)。在这些用户流失之前想办法提高他们的积极性。

流失率

衡量的是在指定时间段内(通常是每月测量)APP 失去用户的比率。结合使用 app 的渠道原因，分析他们离开的原因。

LTV(用户终身价值)

LTV 可以说是所有数据指标中最重要的指标，因为它让你知道，你到底花了多少钱来获得一位新的用户。

要计算用户的 LTV，这里有几个数据点，需要我们知道和了解一下。

收入：这是一个简单的指标，即 APP 产生的所有收入，无论是 APP 广告，应用内购买，付费下载或订阅

活跃用户数：这是对积极用户所用的定义。这其中个人认为应该包括，用户在活跃了一段时间后处于非活动状态用户和尚未在 APP 中购买高级内容的用户。

每用户平均收入(ARPU)：跟踪 ARPU 是很容易做到的，因为它只是收入的生成，ARPU 注重的是一个时间段内运营商从每个用户所得到的利润。很明显,高端的用户越多,ARPU 越高。计算时，只需将收入除以给定时间段内的活跃用户数。

真实用户数

获取用户是推广的第一步。这个阶段你需要做的是①让 App 在十几秒内抓住你的用户②通过应用市场下载③通过广告渠道④找到适合自己的推广渠道。

盈利：目前国内开发者被证实可行的盈利方式包括应用内付费和依靠合作者的运营支付和广告平台这两种，做好了这些，平均转化成本和回报率提高了，盈利就实现了。

后续传播指数 后续传播的一个典型媒介就是社交网络，如果产品自身足够好，有很好的口碑。从自传播到再次获取新用户，应用运营会形成了一个螺旋式上升的轨道。而那些优秀的应用就很好地利用了这个轨道，不断扩大自己的用户群体。

100、 微信的哪些指标重要

文章初次打开率= 会话阅读渠道图文页阅读人数 / 全部图文页阅读人数

阅读人数可能包括转发分享阅读的人数，初次打开率除了可以衡量文章是否吸引人之外，还可以衡量粉丝的活跃度。如果初次打开率持续低于 3%以下，可以视为粉丝活跃度极低。

转发分享率=分享转发次数 / 全部图文阅读人数

统计所有阅读过文章的人，有多大比例分享出去了。可以衡量文章内容质量。比较合理的转发分享率应该持续超过 10%以上。

转发拉粉率 = 粉丝净增人数 / 分享转发次数

衡量每次转发能带来多少粉丝，优化的好，可以超过 100%，如果低于 20-30%，算是拉粉能

力很差。

二次传播率=（转发阅读人数+朋友圈阅读人数） / 总阅读人数

二次传播率意味着文章通过朋友、群组、朋友圈的传播能力。如果二次传播率始终低于 50%，说明用户对公众号的忠诚度很低。

101、假如要策划一个暑期档活动，前期你会从哪些方面做准备呢？

明确活动主题和目标

大概是首先要明确目标用户是谁，针对这个群体的行为习惯和爱好策划活动。

市场分析

竞争对手当前的活动行为分析，有没有推出类似的活动，思考如何创新

网站自身情况

网站本身的实际情况（包括活动的时间、预期投入的费用等），活动策划所需相关的宣传资源，人力资源，物力资源，包括涉及到的部门和人员。

吸收历史经验

此外可以向同事了解往年公司类似活动的方案和最终效果，吸取经验。

102、 怎么复盘一个项目

取得了什么成果

有没有达到预期成果

那个环节好，之后可以借鉴，哪个环节还可以改进

回顾目标

当初行动的意图是什么？事件想要达到的目标是什么？

评估结果

在这一步中，主要回答以下问题：

实际发生了什么事？

在什么情况下，是怎么发生的？

与目标相比，哪些地方做得好？哪些未达预期？

具体：（新用户：多少人注册、多少人付费、转化率

老用户：多少人回购、多少人流失、转化率）

分析原因

这一步要回答的问题包括以下几个：

实际情况与预期有无差异？

如果实际情况与预期有差异，那么，为什么会出现这些差异？是由哪些因素造成？根本原因是什么？

如果实际情况与预期无差异，那么，成功的关键因素是什么？

总结经验

这一步主要回答以下问题：

我们从过程中学到了什么新东西？

如果有人进行同样的行动，我会给他什么建议？
接下来我们该做什么？哪些是可以直接行动的？ /

103、假如最近要上线一个电视剧，你能策划出什么推广活动

电视剧买点：演员、导演；剧情，结合主旋律；
短视频平台宣传（剧集爆料，演员炒作、情节恶搞），软文（新闻、论坛、豆瓣），社交类（微信、微博、qq 看点），搜索类，
主页宣传，卖点提炼
前期的分析：剧集内容的调研、受众人群的分析、类似题材或者频道的数据分析等；
策略的提出：分几个阶段推广、推广的步骤是什么、具体的要求有哪些等；
创意的策划：策划能增加人气的话题创意、视频创意、活动创意、事件创意等；
平台的选择：应该选择哪些渠道进行推广、哪些渠道搭配最好等；
效果的预估：预计能达到什么效果、多少受众观看、网页展示曝光如何等；
风险的评估：如果推广过程中出现意外（收视目标达不到、渠道出问题等）该怎么补救；

104、 如何理解产品经理

一个互联网产品的出现，一定是要满足一部分人的需求、需要，一个不能解决用户需求、需要的产品，只能是昙花一现，所以说，产品的核心在于需求。很多时候，用户的需求并不明显，往往表露出来的仅是表面需要，这个时候，我们需要一个人站出来，挖掘这个需求，把表面需求中的隐含需求找出来，形成可以用于软件设计、软件开发的文档，而我们需要的这个人，就是产品经理。

一个普通产品经理的核心能力，就是需求挖掘。那么产品经理仅仅是要做需求挖掘吗？显然不是的，需求挖掘只是核心能力，不同团队中的产品经理，可能会遇到的情况是不同的。大公司的产品经理，还要兼有团队管理能力，市场分析，销售策略，盈利预测等。

105、 归因分析

如何将用户行为的‘贡献’合理地分配到每一个渠道，这就是归因分析要解决的问题，通过渠道归因来衡量渠道的效果，反过来可以指导业务人员在渠道投放时合理分配投入。

对于归因分析而言，一个很重要的命题即是，针对当前的场景和目标，怎么把“贡献”合理分配到每一个坑位上。下面我们就以站内归因为例，普及一下几种常见的归因分析计算思路。假设一个用户一天内使用 APP 的行为顺序如下：

首先，启动 APP，进入首页，先行搜索，在搜索结果列表页看到了商品 A，浏览了商品 A 的详情，觉得不错，但是并未购买，退出 APP。然后，再次启动 APP，看到首页顶部 Banner，点击进入活动分会场，浏览过程中再次看到商品 A，点击再次查看商品 A 详情。接着，直接

退出到了首页，底部推荐列表中推荐了一篇商品 A 的用户评论，点击进入，再次查看商品 A 的详细信息。最后，下定决心，购买了商品 A。

106、 数据分析步骤

数据抓取→ \rightarrow→ 数据清洗 → \rightarrow→ 数据分析→ \rightarrow→ 业务决策

产生数据： 内部获取、第三方交易、数据爬取

数据清洗： 缺失值处理（前后数字不全、平均值等、删除）、数据格式内容等一致性处理、逻辑错误处理（重复值、不合理值）

数据分析： 描述性分析（What）、诊断性分析(Why)、预测性分析(Will)、规范性分析(How)

业务决策： 通过利用对已发生事件的理解和事件发生的原因，以及各种可能发生的情况分析来帮助确定可采取的最佳行动方案。指导性分析通常是各类分析的组合。

107、 数据分析的作用

精准营销： 网站推荐

精细化运营： 拉新、留存、推送

产品设计： 优化步骤提高转化率

108、 数据分析报告

明确分析目标

确定分析方案

数据获取、数据清洗、统计分析

产生业务洞察

分析报告

109、 用户画像怎么做，选择什么属性

基础属性（人口统计特征：年龄、性别、教育情况、收入情况）、兴趣属性（浏览内容、收藏内容、阅读咨询、购买物品偏好等）、行为属性（访问时间、浏览路径等用户在网站的行为日志数据）、社交属性（用户社交相关数据）、位置与场景（用户所处城市、所处居住区域、用户移动轨迹等）、消费属性、业务属性、资产属性、设备属性（使用的终端特征）

110、 熟悉什么模型，讲一下（RFM 模型）

RFM 模型:

Recency: 最近一次消费时间间隔

Frequency: 消费频次、一段时间内的消费次数

Monetary: 消费金额, 一段时间内的消费金额

消费时间间隔越长, 用户价值越低; 消费总频次/总金额越高, 用户价值越高。

RFM 指标计算:

Step1: 计算用户的 R、F、M 打分

Step2: 计算平均值

Step3: 用户分类

Step4: 对应表格, 找到用户分类

重要价值用户: 保持长期关注, 重点关注, 可考虑 vip 等活动

重要发展客户: 办理会员卡等方式提升客户消费频次

重要保持客户: 给予优惠券等促销活动, 吸引用户回流

重要挽留客户: 定时消息推送及促销优惠

111、Python 基础数据类型有哪些

不可变数据: Number(数字)、String(字符串)、Bool(布尔)、Tuple(元组)

可变数据: List(列表)、Dictionary(字典)、Set(集合)。

112、 数据分析思维

数据+模型=分析结果

数据分析思维: 漏斗思维, 分类思维, 平衡思维, A/B test 等

113、新用户流失和老用户流失有什么不同

来自【面经】数据分析岗_面试题整理总结 (持续更新中...)

新用户流失: 原因可能有非目标用户(刚性流失)、产品不满足需求(自然流失)、产品难以上手(受挫流失)和竞争产品影响(市场流失)。

新用户要考虑如何在较少的数据支撑下做流失用户识别, 提前防止用户流失, 并如何对有效的新用户进行挽回。

老用户流失：原因可能有到达用户生命周期衰退期（自然流失）、过度拉升 arpu 导致低端用户驱逐（刚性流失）、社交蒸发难以满足前期用户需求（受挫流失）和竞争产品影响（市场流失）。

老用户有较多的数据，更容易进行流失用户识别，做好防止用户流失更重要。当用户流失后，要考虑用户生命周期剩余价值，是否需要进行挽回。

114、 识别作弊用户

分类问题可以用机器学习的方法去解决

（1）渠道特征：渠道、渠道次日留存率、渠道流量以及各种比率特征

（2）环境特征：设备（一般伪造假用户的工作坊以低端机为主）、系统（刷机工作坊一般系统更新较慢）、wifi 使用情况、使用时间、来源地区、ip 是否进过黑名单

（3）用户行为特征：访问时长、访问页面、使用间隔、次日留存、活跃时间、页面跳转行为（假用户的行为要么过于一致，要么过于随机）、页面使用行为（正常用户对图片的点击也是有分布的，假用户的行为容易过于随机）

（4）异常特征：设备号异常（频繁重置 idfa）、ip 异常（异地访问）、行为异常（突然大量点击广告、点赞）、数据包不完整等

115、 常用模型

用户画像

漏斗模型

用户行为路径分析

产品基础指标：UV：独立访客数（unique visitor），PV：页面浏览量（Page View），新用户数。

流量质量指标：跳出率：浏览单页就跳出。用户访问时间。留存率。回访率。

产品营收指标：

客单价（ARPU）：客单价=支付有效金额/支付用户数

转化率：订单转化率=有效订单用户数/UV

用户支付金额（GMV）：支付金额即产品某段时间的流水。

销售额=访客数×成交转化率×客单价

销售额=曝光次数×点击率×成交转化率×客单价；

116、 贝壳如果去新的城市扩张， 需要看哪些指标

人：房屋需求量

买房：常住人口/每户人口数*百分比，约 3 人

租房：流动人口

货：
房源，房价

场：市场环境

117、 若贝壳要进入一个新的城市要如何去估计这个城市的需求量

城市发展水平，关系到会有多少人会留在本地，住房买房
现有人口和未来五年的增量人口。

118、 滴滴数据和贝壳数据的区别

滴滴和贝壳都是双边市场的交易平台，包括供给端和需求端额增长、供需两侧交易匹配效率提升、交易平台服务保障。

滴滴是高频低客单价业务，对交易匹配的时效性更高，交付的服务相对标准化，重效率，快速迭代；买卖房是低频高客单价业务，交易周期长，服务个性化要求更高，重形式。
房地产行业革新较慢，也是局部性的。

滴滴：

供给端增长，司机拉新、持续激励；

需求端增长，乘客营销、会员体系；

交易匹配效率，包括设计定价模式（高峰加价、平峰降价）、司乘匹配模式（就近派单、乘客排队、司机抢单）等

平台服务保障，保证交易正常进行。

贝壳：

供给端增长，拉动更多业主报盘，尤其是优质房源和重点楼盘；

需求端增长，通过线上线下渠道，获得更多买房咨询客户，通过经纪人持续维护，让他们成为买房成交客户。

交易保障服务，房屋信息透明、资产安全、交易流程透明、异常情况赔付等。

119、 为客户推荐房源应该怎么分析

用户画像，根据用户在平台上的搜索浏览记录分析用户偏好，是更注重距离、价格、周边设施还是其他。推荐算法。

120、 估计某月某地区二手房的成交量

首先确定一些可参考的数据，比如上月或去年的成交量，在此基础上看是否有一些因素会对成交量产生影响

人货场三个角度，人的角度看涉及经纪人、买房者、业主，货指房屋，比如房价变化，在售房源数等等，场指外部大环境，比如疫情影响之类的。

121、 ‘三孩’政策对房地产的影响

影响房地产的最直接的三大要素为：人口、土地、金融，长期看人口，中期看土地，短期看金融

人口：三孩会刺激提升人口增长率，进一步挖掘人口红利，增加未来潜在购房人数。

房地产：改善住房的户型，未来学区房的竞争压力会增大，政府工作人员购房者比例会增加，马太效应，刚需房购买难度增加，未来二线城市需求会增加。不过对多孩家庭可能会有购房的相关政策。

122、 AB 测试的流程

分析现状：针对当前产品情况，根据业务数据，提出优化方案（一般由数据分析师和产品经理确定）。

确定评估指标：确定衡量优化效果的指标（如：CTR，停留时长等）。

设计与开发：确定优化版本的设计原型，并完成技术实现（通常与数据分析师无关）。

分配流量：确定实验分层分流方案，以及实验需要切分多少流量，一般根据最小样本量确定。

确定实验有效天数：实验的有效天数即为实验进行多少天能达到流量的最小样本量。

采集并分析数据：提取实验数据，对实验结果进行分析。

根据试验结果，确定是否推广到全量或者是调整之后继续实验。

123、 A/B 测试的流程

沟通测试需求

讨论观测指标

选择投放目标

配置实验策略

评估数据结果

124、 知道哪些机器学习算法

线性回归

输出是连续值，用于研究输入与输出的关系，可基于线性回归方程进行预测

逻辑回归

输出是离散值，即 0 或 1，二分类方法

$y = 1 / (1 + e^{-x})$ sigmoid 函数

逻辑回归与线性回归类似，两者的目标都是找出每个输入变量的权重值。不同的是逻辑回归模型是通过特殊的非线性函数来计算输入变量的加权和，逻辑函数或 S 形函数运行结果，以产生输出 y 。值小于 0.5，类别为 0，大于 0.5，类别为 1。

KNN 分类

K 最近邻(KNN)分类的目的是将数据分为不同的类别，我们可以基于相似性度量（例如距离函数）对它们进行分类。

- (1) 计算测试数据与各个训练数据之间的距离
- (2) 按照递增关系进行排序
- (3) 选取距离最小的 K 个点
- (4) 确定前 K 个点所在类别的出现频率
- (5) 返回前 K 个点中出现频率最高的类别作为测试数据的类别

支持向量机

支持向量机(SVM)最初是用于数据分析。首先一组训练实例被输入到 SVM 算法中，它们分别属于一类别或另一个类别。然后，根据这些数据该算法建一个模型，然后将新的测试数据分配给它在训练阶段学习到的类别之一。它的基本模型是在特征空间中寻找间隔最大化的分离超平面的线性分类器。

支持向量机是创建一个超平面，将该超平面作为类别之间的分界，新的测试数据出现在哪一侧就属于哪一类。

- 1) 当训练样本线性可分时,通过硬间隔最大化,学习一个线性分类器,即线性可分支持向量机;
- 2) 当训练数据近似线性可分时,引入松弛变量,通过软间隔最大化,学习一个线性分类器,即线性支持向量机;
- 3) 当训练数据线性不可分时,通过使用核技巧及软间隔最大化,学习非线性支持向量机。

SVM 算法的优缺点

优点:

- 1、可以有效解决高维特征的分类和回归问题
- 2、无需依赖全体样本,只依赖支持向量
- 3、有大量的核技巧可以使用,从而可以应对线性不可分问题
- 4、样本量中等偏小照样有较好的效果

缺点:

- 1、如果特征维度远大于样本个数,SVM 表现一般
- 2、SVM 在样本巨大且使用核函数时计算量很大
- 3、非线性数据的核函数选择依旧没有标准
- 4、SVM 对缺失和噪声数据敏感
- 5、特征的多样性导致限制了 SVM 的使用,因为 SVM 本质上是属于一个几何模型,这个模型需要去定义 instance 之间的 kernel 或者 similarity(线性 SM 中的内积),而我们无法预先设定一个很好的 similarity.这样的数学模型使得 SM 更适合去处理“同性质”的特征。

125、神经网络

K-means 聚类

输入是样本集 $D=\{x_1, x_2, \dots, x_m\}$, 聚类的簇数 k , 最大迭代次数 N

输出是簇划分 $C=\{C_1, C_2, \dots, C_k\}$

- 1) 从数据集 D 中随机选择 k 个样本作为初始的 k 个质心向量: $\{\mu_1, \mu_2, \dots, \mu_k\}$
- 2) 对于 $n=1, 2, \dots, N$
 - a) 将簇划分 C 初始化为 $C_t=\emptyset$, $t=1, 2, \dots, k$
 - b) 对于 $i=1, 2, \dots, m$, 计算样本 x_i 和各个质心向量 $\mu_j(j=1, 2, \dots, k)$ 的距离: $d_{ij}=\|x_i - \mu_j\|^2$, 将 x_i 标记最小的为 d_{ij} 所对应的类别 λ_i 。此时更新 $C\lambda_i=C\lambda_i \cup \{x_i\}$
 - c) 对于 $j=1, 2, \dots, k$, 对 C_j 中所有的样本点重新计算新的质心 $\mu_j=1/|C_j| \sum_{x \in C_j} x$
 - e) 如果所有的 k 个质心向量都没有发生变化, 则转到步骤 3)
- 3) 输出簇划分 $C=\{C_1, C_2, \dots, C_k\}$

K-means 的 k 如何选择

对 kmeans 聚类如何选择 k

肘部法则 (Elbow Method)

k-means 是以最小化样本与质点平方误差作为目标函数, 将每个簇的质点与簇内样本点的平方距离误差和称为畸变程度。对于一个簇, 它的畸变程度越低, 代表簇内成员越紧密, 畸变程度会随着类别的增加而降低, 但对于有一定区分度的数据, 在达到某个临界点时畸变程度会得到极大改善, 之后缓慢下降, 这个临界点就可以考虑为聚类性能较好的点。基于这个指标, 我们可以重复训练多个 k-means 模型, 选取不同的 k 值, 来得到相对合适的聚类类别。

轮廓系数 (Silhouette Coefficient)

对于一个聚类任务, 我们希望得到的簇中, 簇内尽量紧密, 簇间尽量远离, 轮廓系数便是类的密集与分散程度的评价指标, 公式表达如下: $s(i) = (b(i) - a(i)) / \max\{a(i), b(i)\}$ 。 a 代表同簇样本到彼此间距离的均值, b 代表样本到除自身所在簇外的最近簇的样本的均值, s 取值在 $[-1, 1]$ 之间。如果 s 接近 1, 代表样本所在簇合理, 若 s 接近 -1 代表 s 更应该分到其他簇中。同样, 利用上述指标, 训练多个模型, 对比选取合适的聚类类别:

3. 根据需要确定
4. 对于低维度的数据可以观察得到

递归神经网络 (RNN)

RNN 本质上是一种神经网络，它在每个节点上都有一个存储器，这使得处理顺序数据变得容易，即一个数据单元依赖于前一个数据单元。

一种解释 RNN 优于常规神经网络的优势的方法是，我们应该逐个字符地处理一个单词。如果单词是 "trading"，则正常的神经网络节点会在移动到 "d" 时忘记字符 "t"，而递归神经网络会记住该字符，因为它具有自己的记忆。

线性判别分析

传统的逻辑回归仅限于二分类问题。如果你有两个以上的类，那么线性判别分析算法 (Linear Discriminant Analysis, 简称 LDA) 是首选的线性分类技术。

LDA 的表示非常简单。它由你的数据的统计属性组成，根据每个类别进行计算。对于单个输入变量，这包括：

1. 每类的平均值。
2. 跨所有类别计算的方差。
3. 计算类内类外矩阵
4. 求最大的几个特征值和特征向量，得到投影矩阵 W
5. 对样本中的每一个样本，转化为新的样本 Wx 。

朴素贝叶斯

朴素贝叶斯是一种简单但极为强大的预测建模算法。

该模型由两种类型的概率组成，可以直接从你的训练数据中计算出来：1) 每个类别的概率；2) 给定的每个 x 值的类别的条件概率。一旦计算出来，概率模型就可以用于使用贝叶斯定理对新数据进行预测。当你的数据是数值时，通常假设高斯分布（钟形曲线），以便可以轻松估计这些概率。

集成学习

RF、GBDT 和 XGBoost 都属于集成学习 (Ensemble Learning)，集成学习的目的是通过结合多个基学习器的预测结果来改善单个学习器的泛化能力和鲁棒性。

根据个体学习器的生成方式，目前的集成学习方法大致分为两大类：即个体学习器之间存在强依赖关系、必须串行生成的序列化方法，以及个体学习器间不存在强依赖关系、可同时生成的并行化方法；前者的代表就是 Boosting、Adaboost、GBDT (Gradient Boosting Decision Tree)、Xgboost，后者的代表是 Bagging 和“随机森林” (Random Forest)。

决策树 (Decision Tree)

决策树通过把样本实例从根节点排列到某个叶子节点来对其进行分类。树上的每个非叶子节

点代表对一个属性取值的测试，其分支就代表测试的每个结果;而树上的每个叶子节点均代表一个分类的类别，树的最高层节点是根节点。

决策树采用自顶向下的递归方式，从树的根节点开始，在它的内部节点上进行属性值的测试比较。然后按照给定实例的属性值确定对应的分支，最后在决策树的叶子节点得到结论。这个过程在以新的节点为根的新树上重复。

简单来说：类似树的结构将输入数据根据不同分类标准进行分类，层层划分。

优点：

决策树容易理解和实现。

对于决策树，数据的准备往往是比较简单或者是不必要的。其它技术往往要求先把数据归一化，比如去掉多余的或者空白的属性。

能够同时处理数据型和常规型属性。其它的技术往往要求数据属性的单一。

是一个白盒模型。如果给定一个观察的模型，那么根据所产生的决策树很容易推出相应的逻辑表达式。

缺点：

对于各类别样本数量不一致的数据，在决策树当中信息增益的结果偏向于那些具有更多数值的特征。

决策树内部节点的判别具有明确性，这种明确性可能会带来误导。

决策树的缺点是由于其固有的设计结构而易于过度拟合。

随机森林(Random Forest)

一个随机森林算法旨在解决一些决策树泛化能力弱的缺点。

随机森林由决策树组成，决策树是代表决策过程或统计概率的决策图。这些多个树映射到单个树，称为分类或回归(CART)模型。

随机森林算法基于 Bootstrap 方法重采样，产生多个训练集。不同的是，随机森林算法在构建决策树的时候，采用了随机选取分裂属性集的方法。

随机森林是最流行和最强大的机器学习算法之一。它是一种被称为 Bootstrap Aggregation 或 Bagging 的集成机器学习算法。

bootstrap 是一种强大的统计方法，用于从数据样本中估计某一数量，例如平均值。它会抽取大量样本数据，计算平均值，然后平均所有平均值，以便更准确地估算真实平均值。

在 bagging 中用到了相同的方法，但最常用到的是决策树，而不是估计整个统计模型。它会训练数据进行多重抽样，然后为每个数据样本构建模型。当你需要对新数据进行预测时，每个模型都会进行预测，并对预测结果进行平均，以更好地估计真实的输出值。

随机森林在 bagging 的基础上更进一步,引入了随机特征选择：

样本的随机：从样本集中用 Bootstrap 随机选取 n 个样本

特征的随机：从所有属性中随机选取 K 个属性，选择最佳分割属性作为节点建立 CART 决策树（泛化的理解，这里面也可以是其他类型的分类器，比如 SVM、Logistics）

重复以上两步 m 次，即建立了 m 棵 CART 决策树

这 m 个 CART 形成随机森林，通过投票表决结果，决定数据属于哪一类（投票机制有一票否决制、少数服从多数、加权多数）

随机选择特征是指在树的构建中，会从样本集的特征集合中随机选择部分特征，然后再从这个子集中选择最优的属性用于划分，这种随机性导致随机森林的偏差会有稍微的增加（相比于单棵不随机树），但是由于随机森林的‘平均’特性，会使得它的方差减小，而且方差的减小补偿了偏差的增大，因此总体而言是更好的模型。

RF 的重要特性是不用对其进行交叉验证或者使用一个独立的测试集获得无偏估计，它可以在内部进行评估，也就是说在生成的过程中可以对误差进行无偏估计，由于每个基学习器只使用了训练集中约 63.2% 的样本，剩下约 36.8% 的样本可用做验证集来对其泛化性能进行“包外估计”。

RF 和 Bagging 对比：RF 的起始性能较差，特别当只有一个基学习器时，随着学习器数目增多，随机森林通常会收敛到更低的泛化误差。随机森林的训练效率也会高于 Bagging，因为在单个决策树的构建中，Bagging 使用的是‘确定性’决策树，在选择特征划分结点时，要对所有的特征进行考虑，而随机森林使用的是‘随机性’特征数，只需考虑特征的子集。

随机森林的优点较多，简单总结：1、在数据集上表现良好，相对于其他算法有较大的优势（训练速度、预测准确度）；2、能够处理很高维的数据，并且不用特征选择，而且在训练完后，给出特征的重要性；3、容易做成并行化方法。

RF 的缺点：在噪声较大的分类或者回归问题上回过拟合。

Bagging

放回抽样，多数表决（分类）或简单平均（回归），同时 Bagging 的基学习器之间属于并列生成，不存在强依赖关系。

Bagging 步骤：

另原始数据集为 $D(n)$ 个样本)，

1. for $i=1$ to T

2. 从 D 中独立随机抽取 m 个数据 ($m < n$)，形成数据集 m_i, m_{im}
 i

3. 用 m_i, m_{im}
 i

训练一个分类器

4.end

5.所有分类器的判决结果投票决定最终的分类结果

关于调参：

1.如何选取 K，可以考虑有 N 个属性，取 $K=\sqrt{N}$

2.最大深度（不超过 8 层）

3.棵数

4.最小分裂样本树

5.类别比例

Boosting

Boosting 是一种从一些弱分类器中创建一个强分类器的集成技术。它先由训练数据构建一个模型，然后关注被已有分类器错分的那些数据来获得新的分类器，不断添加模型，直到训练集完美预测或已经添加到数量上限,Boosting 分类的结果是基于所有分类器的加权求和结果的，分类器权重并不相等，每个权重代表对应的分类器在上一轮迭代中的成功度。

GBDT

GBDT 与传统的 Boosting 区别较大，它的每一次计算都是为了减少上一次的残差，而为了消除残差，我们可以在残差减小的梯度方向上建立模型,所以说，在 GradientBoost 中，每个新的模型的建立是为了使得之前的模型的残差往梯度下降的方法，与传统的 Boosting 中关注正确错误的样本加权有着很大的区别。

在 GradientBoosting 算法中，关键就是利用损失函数的负梯度方向在当前模型的值作为残差的近似值，进而拟合一棵 CART 回归树。

GBDT 的会累加所有树的结果，而这种累加是无法通过分类完成的，因此 GBDT 的树都是 CART 回归树，而不是分类树（尽管 GBDT 调整后也可以用于分类但不代表 GBDT 的树为分类树）。

GBDT 的性能在 RF 的基础上又有一步提升，因此其优点也很明显，1、它能灵活的处理各种类型的数据；2、在相对较少的调参时间下，预测的准确度较高。

当然由于它是 Boosting，因此基学习器之前存在串行关系，难以并行训练数据。

XGBoost 与 GBDT 的区别

XGBoost 的性能在 GBDT 上又有一步提升,XGBoost 最大的认知在于其能够自动地运用 CPU 的多线程进行并行计算，同时在算法精度上也进行了精度的提高。

由于 GBDT 在合理的参数设置下，往往要生成一定数量的树才能达到令人满意的准确率，在数据集较复杂时，模型可能需要几千次迭代运算。但是 XGBoost 利用并行的 CPU 更好的解

决了这个问题。

xgboost 与 gbdtd 比较大的不同就是目标函数的定义。

优点：

1、传统的 GBDT 以 CART 树作为基学习器，XGBoost 还支持线性分类器，这个时候 XGBoost 相当于 L1 和 L2 正则化的逻辑斯蒂回归（分类）或者线性回归（回归）；

传统的 GBDT 在优化的时候只用到一阶导数信息，XGBoost 则对代价函数进行了二阶泰勒展开，得到一阶和二阶导数；

2、XGBoost 在代价函数中加入了正则项，用于控制模型的复杂度。从权衡方差偏差来看，它降低了模型的方差，使学习出来的模型更加简单，防止过拟合，这也是 XGBoost 优于传统 GBDT 的一个特性；

3、shrinkage（缩减），相当于学习速率（XGBoost 中的 eta）。XGBoost 在进行完一次迭代时，会将叶子节点的权值乘上该系数，主要是为了削弱每棵树的影响，让后面有更大的学习空间。（GBDT 也有学习速率）

4、列抽样。XGBoost 借鉴了随机森林的做法，支持列抽样，不仅防止过拟合，还能减少计算；

5、对缺失值的处理。对于特征的值有缺失的样本，XGBoost 还可以自动学习出它的分裂方向；

6、XGBoost 工具支持并行。

缺点：

1、level-wise 建树方式对当前层的所有叶子节点一视同仁，有些叶子节点分裂收益非常小，对结果没影响，但还是要分裂，加重了计算代价。

2、预排序方法空间消耗比较大，不仅要保存特征值，也要保存特征的排序索引，同时时间消耗也大，在遍历每个分裂点时都要计算分裂增益(不过这个缺点可以被近似算法所克服)

AdaBoost（Adaptive Boosting，自适应增强）

AdaBoost 是为二分类开发的第一个真正成功的 Boosting 算法，同时也是理解 Boosting 的最佳起点。目前基于 AdaBoost 而构建的算法中最著名的就是随机梯度 boosting。

它的自适应在于：前一个基本分类器分错的样本会得到加强，加权后的全体样本再次被用来训练下一个基本分类器。同时，在每一轮中加入一个新的弱分类器，直到达到某个预定的足够小的错误率或达到预先指定的最大迭代次数。

整个 Adaboost 迭代算法就 3 步：

初始化训练数据的权值分布。如果有 N 个样本，则每一个训练样本最开始时都被赋予相同的权值： $1/N$ 。

训练弱分类器。具体训练过程中，如果某个样本点已经被准确地分类，那么在构造下一个训练集中，它的权值就被降低；相反，如果某个样本点没有被准确地分类，那么它的权值就得到提高。然后，权值更新过的样本集被用于训练下一个分类器，整个训练过程如此迭代地进行下去。

将各个训练得到的弱分类器组合成强分类器。各个弱分类器的训练过程结束后，加大分类误差率小的弱分类器的权重，使其在最终的分类函数中起着较大的决定作用，而降低分类误差

率大的弱分类器的权重，使其在最终的分类函数中起着较小的决定作用。换言之，误差率低的弱分类器在最终分类器中占的权重较大，否则较小。

AdaBoost 常与短决策树一起使用。在创建第一棵树之后，每个训练实例在树上的性能都决定了下一棵树需要在这个训练实例上投入多少关注。难以预测的训练数据会被赋予更多的权重，而易于预测的实例被赋予更少的权重。模型按顺序依次创建，每个模型的更新都会影响序列中下一棵树的学习效果。在建完所有树之后，算法对新数据进行预测，并且通过训练数据的准确程度来加权每棵树的性能。

126、GBM 与 XGBoost 的区别

xgboost 采用的是 level-wise 的分裂策略，而 lightGBM 采用了 leaf-wise 的策略，区别是 xgboost 对每一层所有节点做无差别分裂，可能有些节点的增益非常小，对结果影响不大，但是 xgboost 也进行了分裂，带来了无必要的开销。leaf-wise 的做法是在当前所有叶子节点中选择分裂收益最大的节点进行分裂，如此递归进行，很明显 leaf-wise 这种做法容易过拟合，因为容易陷入比较高的深度中，因此需要对最大深度做限制，从而避免过拟合。

lightgbm 使用了基于 histogram 的决策树算法，这一点不同与 xgboost 中的 exact 算法，histogram 算法在内存和计算代价上都有不小优势。

lightgbm 支持直接输入 categorical 的 feature

在对离散特征分裂时，每个取值都当作一个桶，分裂时的增益算的是“是否属于某个 category”的 gain。类似于 one-hot 编码。

多线程优化

127、查看后台进程

jobs

查看当前控制台的后台进程

想要停止后台进程，使用 jobs 命令查看其进程号（比如为 num），然后 kill %num 即可

ps

查看后台进程

top

查看所有进程和资源使用情况，类似 Windows 中的任务管理器

停止进程:界面是交互式的，在窗口输入 k 之后输入 PID，会提示输入停止进程模式 有 SIGTERM 和 SIGKILL，如果留空不输入，就是 SIGTERM（优雅停止）

退出 top:输入 q 即可

128、删除当前文件夹下 2018 年-2019 年文件命令

rm -rf 文件名

129、 修改文件权限命令、有哪些权限

rwX: r 代表可读, w 代表可写, x 代表该文件是一个可执行文件, 如果 rwX 任意位置变为- 则代表不可读或不可写或不可执行文件。

示例: 给 aaa.txt 文件权限改为可执行文件权限, aaa.txt 文件的权限是-rw- --- ---

第一位: -就代表是文件, d 代表是文件夹

第一段 (3 位): 代表拥有者的权限

第二段 (3 位): 代表拥有者所在的组, 组员的权限

第三段 (最后 3 位): 代表的是其他用户的权限

421 421 421

- rw- --- ---

代表拥有者可读可写, 不可执行, 组员和其他用户没有任何权限

1

2

3

9.计算机网络

130、http 协议与 TCP 的区别与联系

联系: Http 协议是建立在 TCP 协议基础之上的, 当浏览器需要从服务器获取网页数据的时候, 会发出一次 Http 请求。Http 会通过 TCP 建立起一个到服务器的连接通道, 当本次请求需要的数据传输完毕后, Http 会立即将 TCP 连接断开, 这个过程是很短的。

区别:HTTP 和 TCP 位于不同的网络分层。TCP 是传输层的协议, 定义的是数据传输和连接的规范, 而 HTTP 是应用层的, 定义的是数据的内容的规范。

建立一个 TCP 请求需要进行三次握手, 而由于 http 是建立在 tcp 连接之上的, 建立一个 http 请求通常包含请求和响应两个步骤。

131、 http 的状态码 403 201 等等是什么意思

常见的状态码有:

200 -请求成功

301 -资源 (网页等) 被永久转移到其它 URL

404-请求的资源 (网页等) 不存在

500-内部服务器错误

400-请求无效

403-禁止访问

132、 http 和 https 的区别，由 http 升级为 https 需要做哪些操作

http 是超文本传输协议，信息是明文传输，https 则是具有安全性的 ssl 加密传输协议
http 和 https 使用的是完全不同的连接方式，用的端口也不一样，前者是 80，后者是 443
http 的连接很简单，是无状态的；HTTPS 协议是由 SSL+HTTP 协议构建的可进行加密传输、身份认证的网络协议，比 http 协议安全。

https 协议需要到 ca 申请证书，一般免费证书较少，因而需要一定费用

133、 一个机器能够使用的端口号上限是多少，为什么？可以改变吗？那如果想要用的端口超过这个限制怎么办？

65536. 因为 TCP 的报文头部中源端口号和目的端口号的长度是 16 位，也就是可以表示 $2^{16}=65536$ 个不同端口号，因此 TCP 可供识别的端口号最多只有 65536 个。但是由于 0 到 1023 是知名服务端口，所以实际上还要少 1024 个端口号。

而对于服务器来说，可以开的端口号与 65536 无关，其实是受限于 Linux 可以打开的文件数量，并且可以通过 MaxUserPort 来进行配置。

134、 单条记录高并发访问的优化

服务器端:

使用缓存，如 redis 等

使用分布式架构进行处理

将静态页面和静态资源存储在静态资源服务器，需要处理的数据使用服务器进行计算后返回。将静态资源尽可能在客户端进行缓存

采用 nginx 进行负载均衡(nginx 读作恩静埃克斯= Engine X)

数据库端:

数据库采用主从赋值，读写分离措施。

建立适当的索引

分库分表

135、 一个 ip 配置多个域名，靠什么识别？

靠 host 主机名区分

靠端口号区分

136、介绍一下 Hadoop

Hadoop 是一套大数据解决方案，提供了一套分布式的系统基础架构，包括 HDFS，MapReduce 和 YARN。

HDFS 提供分布式的数据存储。

MapReduce 负责进行数据运算

YARN 负责任务调度

HDFS 是主从架构的，包括 namenode，secondarynamenode 和 datanode。datanode 负责存储数据，namenode 负责管理 HDFS 的目录树和文件元信息。

MapReduce 包括 jobtracker,tasktracker 和 client。Jobtracker 负责进行资源调度和作业监控。tasktracker 会周期性的通过心跳向 jobtracker 汇报资源使用情况。

137、说一下 MapReduce 的运行机制

MapReduce 包括输入分片、map 阶段、combine 阶段、shuffle 阶段和 reduce 阶段。分布式计算框架包括 client，jobtracker 和 tasktracker 和调度器。

输入分片阶段，mapreduce 会根据输入文件计算分片，每个分片对应一个 map 任务

map 阶段会根据 mapper 方法的业务逻辑进行计算，映射成键值对

combine 阶段是在节点本机进行一个 reduce，减少传输结果对带宽的占用

shuffle 阶段是对 map 阶段的结果进行分区，排序，溢出然后写入磁盘。将 map 端输出的无规则的数据整理成为有一定规则的数据，方便 reduce 端进行处理，有点像洗牌的逆过程。

reduce 阶段是根据 reducer 方法的业务逻辑进行计算，最终结果会存在 hdfs 上。

138、介绍一下 spark

spark 是一个通用内存并行计算框架。它可以在内存中对数据进行计算，效率很高，spark 的数据被抽象成 RDD(弹性分布式数据集) 并且拥有 DAG 执行引擎，兼容性和通用性很好。可以和 Hadoop 协同工作。

139、100 层楼，只有 2 个鸡蛋，想要判断出那一层刚好让鸡蛋碎掉，给出策略(滴滴笔试中两个铁球跟这个是一类题)

(给定了楼层数和鸡蛋数的情况) 二分法+线性查找从 $100/2=50$ 楼扔起，如果破了就用另一个从 0 扔起直到破。如果没破就从 $50/2=25$ 楼扔起，重复。

动态规划

140、 毒药问题，1000 瓶水，其中有一瓶可以无限稀释的毒药，要快速找出哪一瓶有毒，需要几只小白鼠

用二进制的思路解决问题。2 的十次方是 1024，使用十只小鼠喝一次即可。方法是先将每瓶水编号，同时 10 个小鼠分别表示二进制中的一个位。将每瓶水混合到水瓶编号中二进制为 1 的小鼠对应的水中。喝完后统计，将死亡小鼠对应的位置为 1，没死的置为 0，根据死亡小鼠的编号确定有毒的是哪瓶水，如 0000001010 表示 10 号水有毒。