

数据分析笔试题

1、用一种编程语言，实现 $1+2+3+4+5+...+100$ 。

这道题考察的就是语言基础，你可以用自己熟悉的语言完成这道题，比如

Python、Java、PHP、C++ 等。这里我用 Python 举例：sum = 0for

number in range(1,101): sum = sum + numberprint(sum)

```
sum = 0
for number in range(1,101):
    sum = sum + number
print(sum)
```

2、如何理解过拟合？

过拟合和欠拟合一样，都是数据挖掘的基本概念。过拟合指的就是数据训练得太好，在实际的测试环境中可能会产生错误，所以适当的剪枝对数据挖掘算法来说也是很重要的。

欠拟合则是指机器学习得不充分，数据样本太少，不足以让机器形成自我认知。

3、为什么说朴素贝叶斯是“朴素”的？

朴素贝叶斯是一种简单但极为强大的预测建模算法。之所以称为朴素贝叶斯，是因为它假设每个输入变量是独立的。这是一个强硬的假设，实际情况并不一定，但是这项技术对于绝大部分的复杂问题仍然非常有效。

4、SVM 最重要的思想是什么？

SVM 计算的过程就是帮我们找到超平面的过程，它有个核心的概念叫：分类间隔。SVM 的目标就是找出所有分类间隔中最大的那个值对应的超平面。在数学上，这是一个凸优化问题。同样我们根据数据是否线性可分，把 SVM 分成硬间隔 SVM、软间隔 SVM 和非线性 SVM。

5、K-Means 和 KNN 算法的区别是什么？

首先，这两个算法解决的是数据挖掘中的两类问题。K-Means 是聚类算法，KNN 是分类算法。其次，这两个算法分别是两种不同的学习方式。K-Means 是非监督学习，也就是不需要事先给出分类标签，而 KNN 是有监督学习，需要我们给出训练数据的分类标识。最后，K 值的含义不同。K-Means 中的 K 值代表 K 类。KNN 中的 K 值代表 K 个最接近的邻居。

动手题

1、我给你一组数据，如果要你做数据清洗，你会怎么做？

姓名	语文	英语	数学
张飞	66	65	-
关羽	95	85	98
赵云	95	92	96
黄忠	90	88	77
典韦	80	90	90
典韦	80	90	90

实际上，这一道题中，面试官考核的是基本的数据清洗的准则，数据清洗是数据分析必不可少的重要环节。你可能看到这个数据存在 2 个问题：典韦出现了 2 次，张飞的数学成绩缺失。

针对重复行，你需要删掉其中的一行。针对数据缺失，你可以将张飞的数学成绩补足。

在「数据科学家 80% 时间都花费在了这些清洗任务上？」的文章里，结合案例，我着重讲解了数据清洗具体方法，我将数据清洗规则总结为以下 4 个关键点，统一起来叫“**完全合一**”，下面我来解释下。

- 1、**完整性**：单条数据是否存在空值，统计的字段是否完善。
- 2、**全面性**：观察某一系列的全部数值，比如在 Excel 表中，我们选中一系列，可以看到该列的平均值、最大值、最小值。我们可以通过常识来判断该列是否有问题，比如：数据定义、单位标识、数值本身。
- 3、**合法性**：数据的类型、内容、大小的合法性。比如数据中存在非 ASCII 字符，性别存在了未知，年龄超过了 150 岁等。

4、**唯一性**：数据是否存在重复记录，因为数据通常来自不同渠道的汇总，重复的情况是常见的。行数据、列数据都需要是唯一的，比如一个人不能重复记录多次，且一个人的体重也不能在列指标中重复记录多次。